Применение метода grid warping для повышения разрешения карт глубины

Карта глубины (depth map)

- Представление 3D-информации о сцене
- Способы получения:
  - Пассивные методы: стереозрение (оценка глубины на основе бинокулярного параллакса)
  - Активные методы: лазерные сканеры, камеры time-of-flight (Microsoft Kinect, SoftKinect)
- Приложения:
  - Робототехника и системы помощи водителю
  - Обработка 3D-изображений

Проблемы карт глубины

- Ограничения оборудования: низкое разрешение и качество по сравнению с цветными изображениями
- Артефакты: внутренние (пространственные, временные), артефакты сжатия

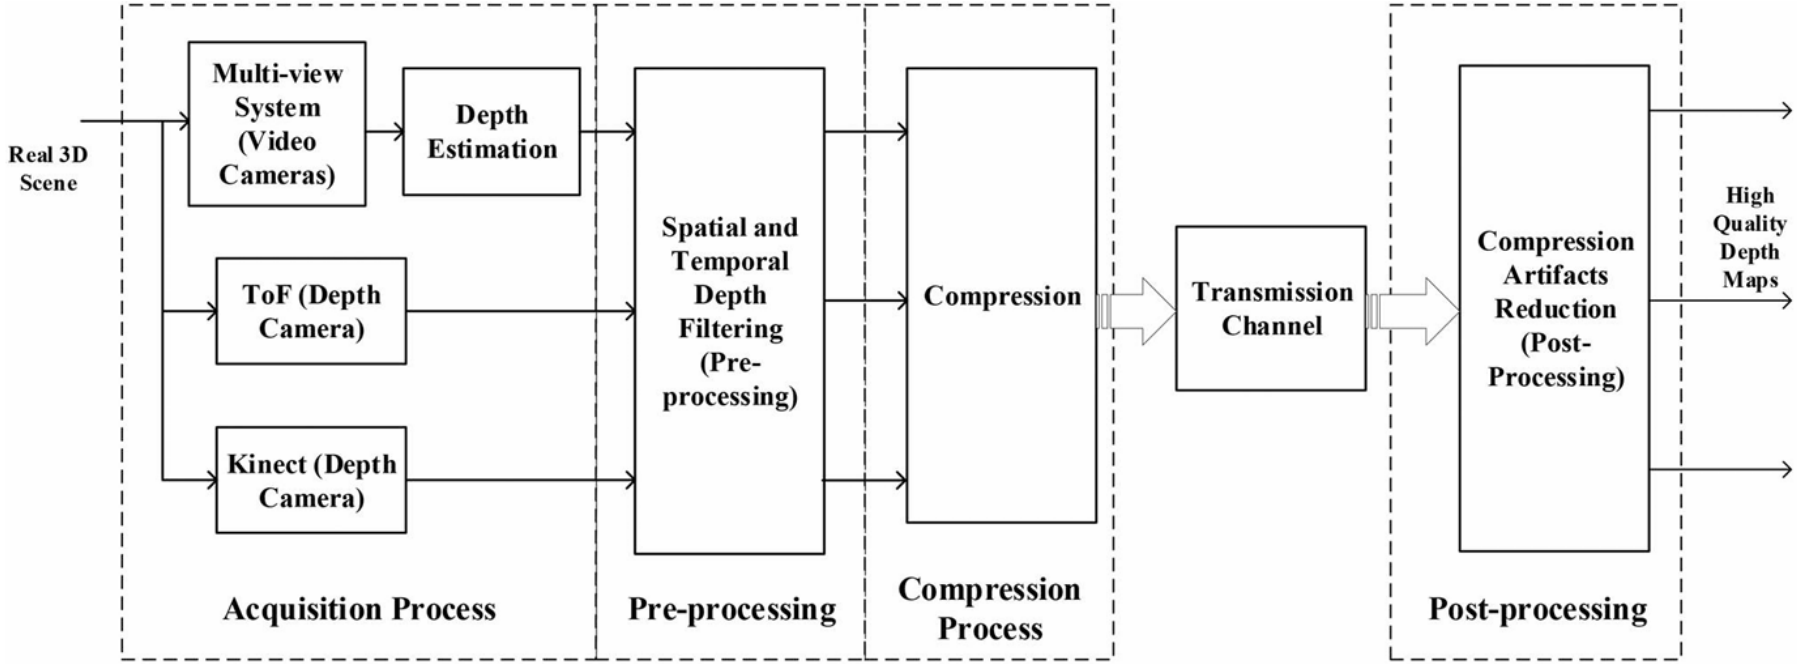

Проблема определения ширины границы

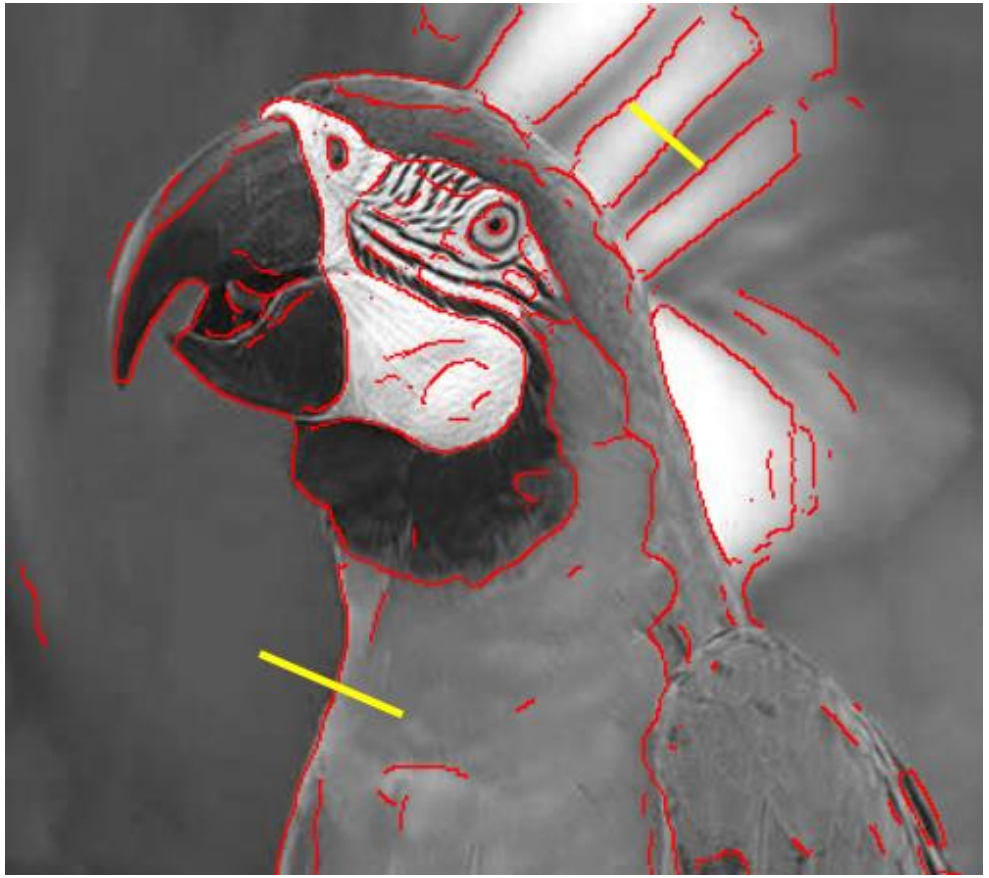

Граница изображения

Профиль границы изображения

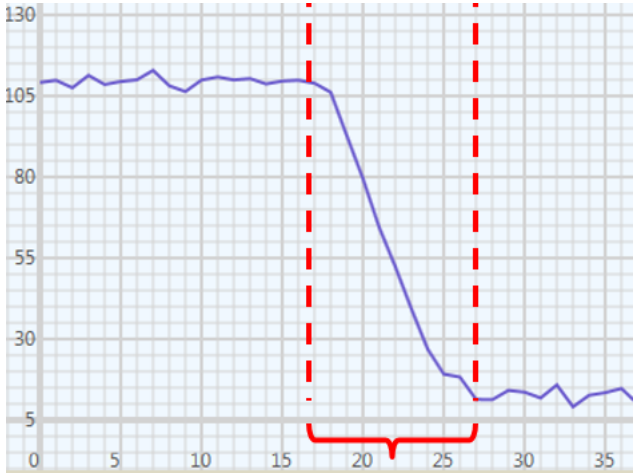

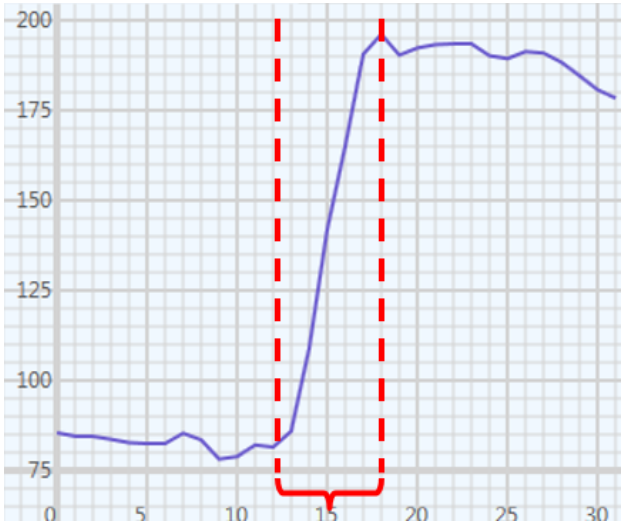

Модель профиля границы изображения

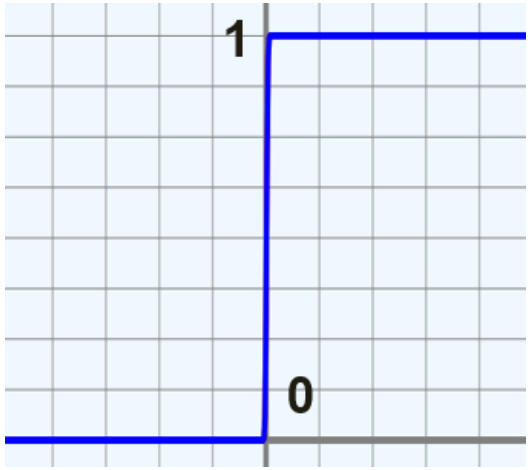

$*$

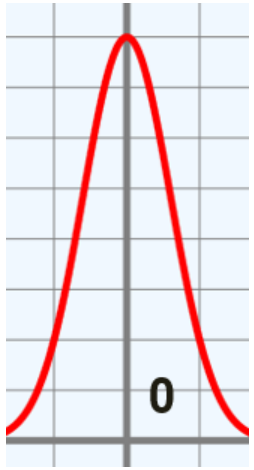

$=$

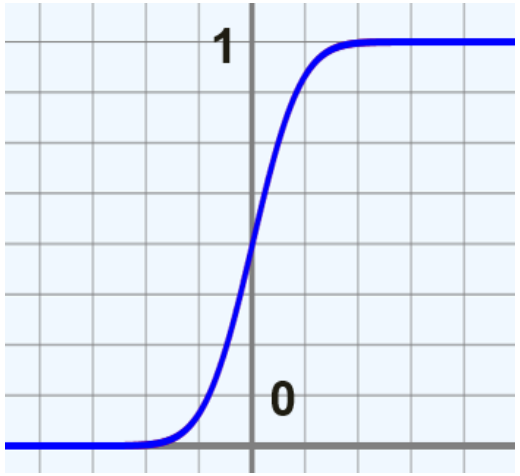

$$H(x)=\begin{cases}1, x\geq 0,\\ 0, x<0\end{cases}$$

$$G_\sigma(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{x^2}{2\sigma^2}}$$

$$E_\sigma(x)=\int_{-\infty}^{\infty}H(t)\cdot G_\sigma(x-t)dt$$

$E_\sigma(x)$ – модельный профиль границы изображения

σ – ширина границы изображения

Нерезкое маскирование (unsharp masking)

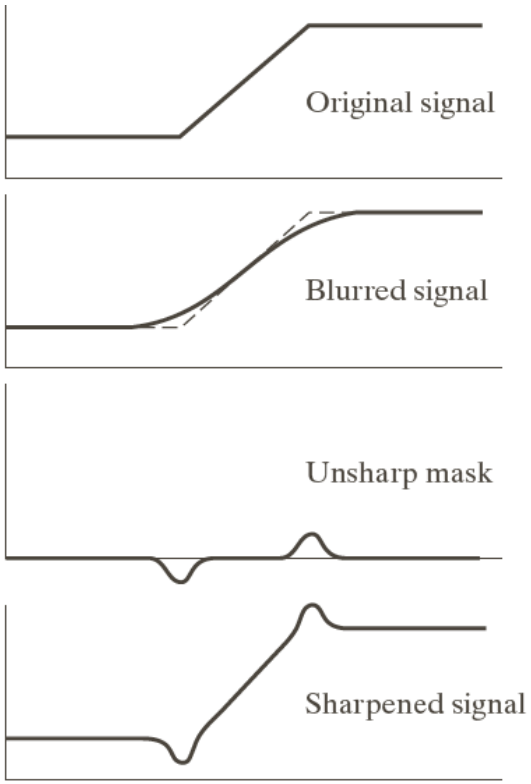

a
b
c
d

FIGURE 3.39 1-D illustration of the mechanics of unsharp masking. (a) Original signal. (b) Blurred signal with original shown dashed for reference. (c) Unsharp mask. (d) Sharpened signal, obtained by adding (c) to (a).

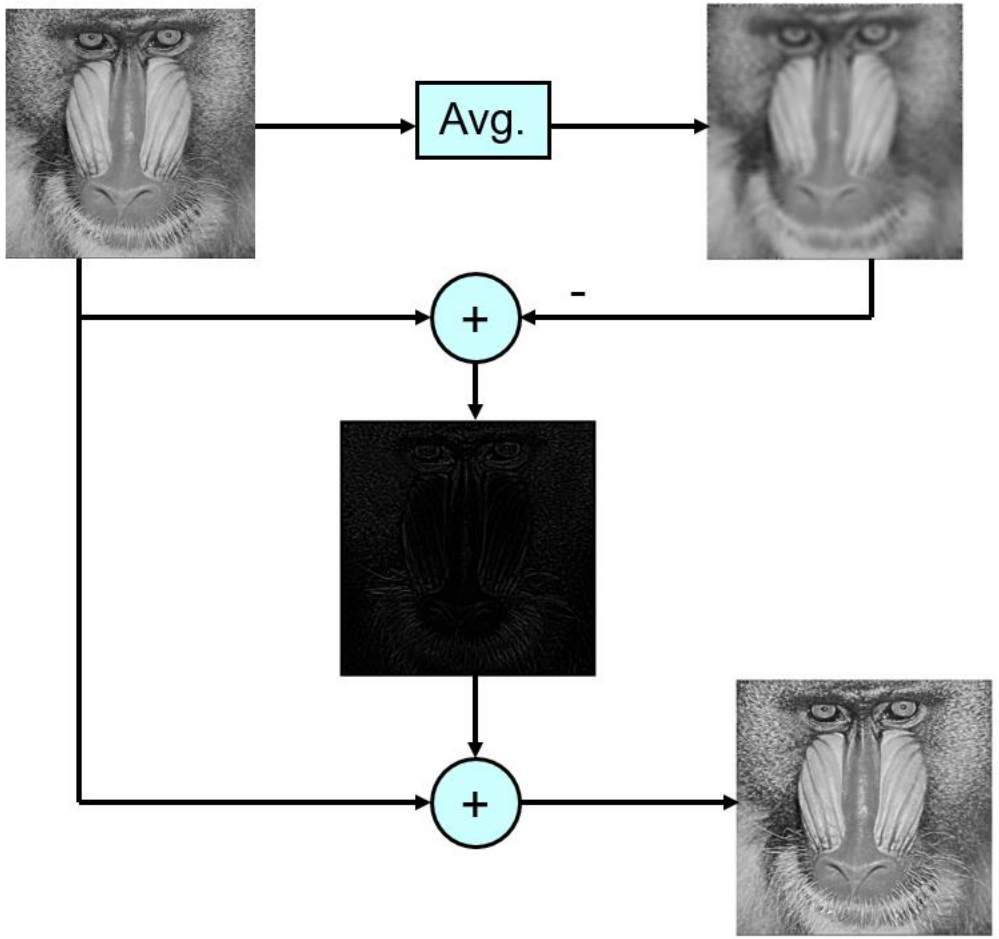

Нерезкое маскирование (unsharp masking)

$$U_{\sigma,\alpha}[S](x) = S * G_\sigma + (1+\alpha)(S - S * G_\sigma) \qquad \begin{Bmatrix} \sigma > 0 \\ \alpha > 0 \end{Bmatrix}$$

Результат - повышение высоких частот

В дальнейшем значение α считается фиксированным (α=4),

$$U_{\sigma,\alpha}[E_{\sigma_0}] \equiv U_\sigma^{(\sigma_0)}$$

Свойства нерезкого маскирования

$$1^\circ.\ U_{\sigma_1}^{(\sigma_1)}(x) = U_{\sigma_2}^{(\sigma_2)}\left(\frac{\sigma_2}{\sigma_1}x\right)$$

$$\boxed{\max_x U_\sigma^{(\sigma)}(x) = U_E \quad \forall \sigma}$$

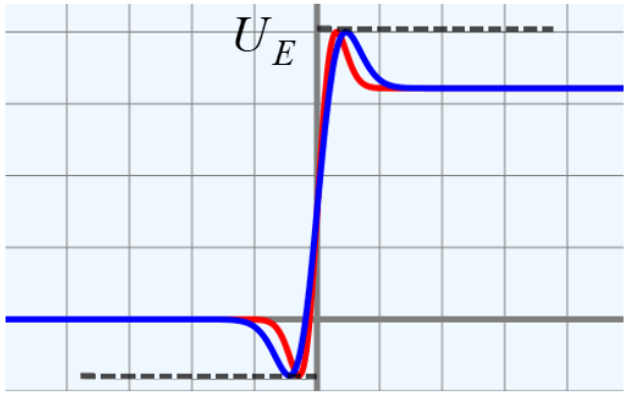

$$2^\circ.\ \max_x U_\sigma^{(\sigma_0)}(x) \le U_E,\ \ \sigma \le \sigma_0$$

$$\max_x U_\sigma^{(\sigma_0)}(x) \ge U_E,\ \ \sigma \ge \sigma_0$$

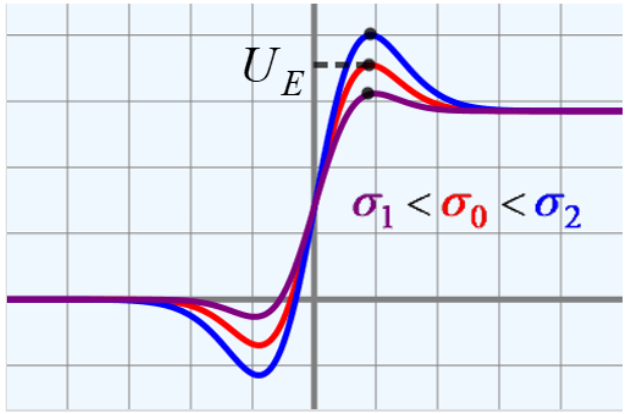

Оценка ширины профиля границы

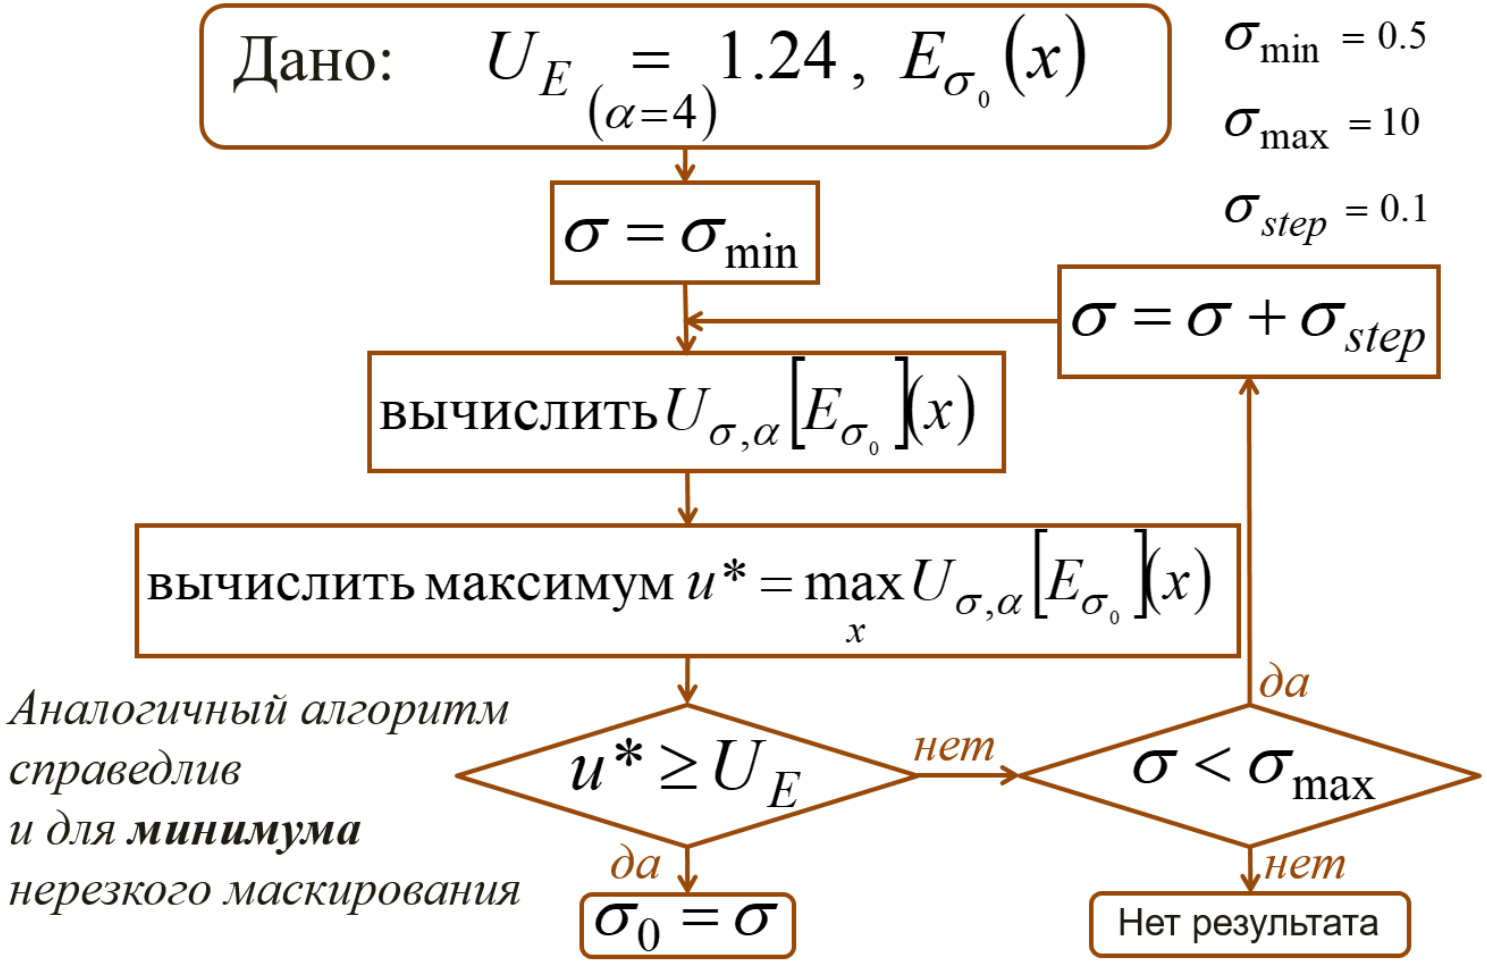

Аналогичный алгоритм справедлив и для ***минимума*** *нерезкого маскирования*

Оценка ширины профиля границы при наличии шума

$$\widetilde{E}_{\sigma_0}(x) = E_{\sigma_0}(x) + N(x)$$

зашумленный профиль границы

модельный профиль границы

аддитивный шум

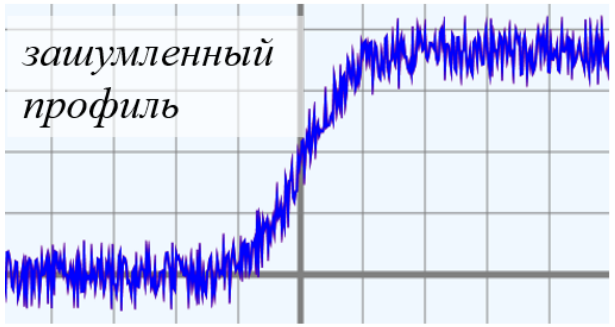

предварительное размытие

$$* \, G_{\sigma_B}(x) =$$

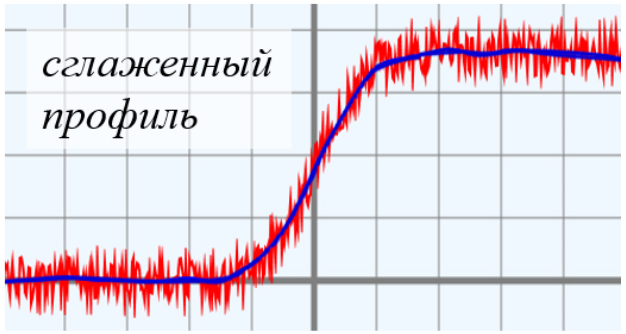

$$\sigma_0 = \sqrt{\widetilde{\sigma}_0^{\,2} - \sigma_B^2}$$

Алгорит оценки ширины профиля границы

Деформация пиксельной сетки (grid warping)

- Деформация пиксельной сетки изображения для смещения пикселей к границам
- Преимущества: сохранение значений пикселей, отсутствие увеличения шума

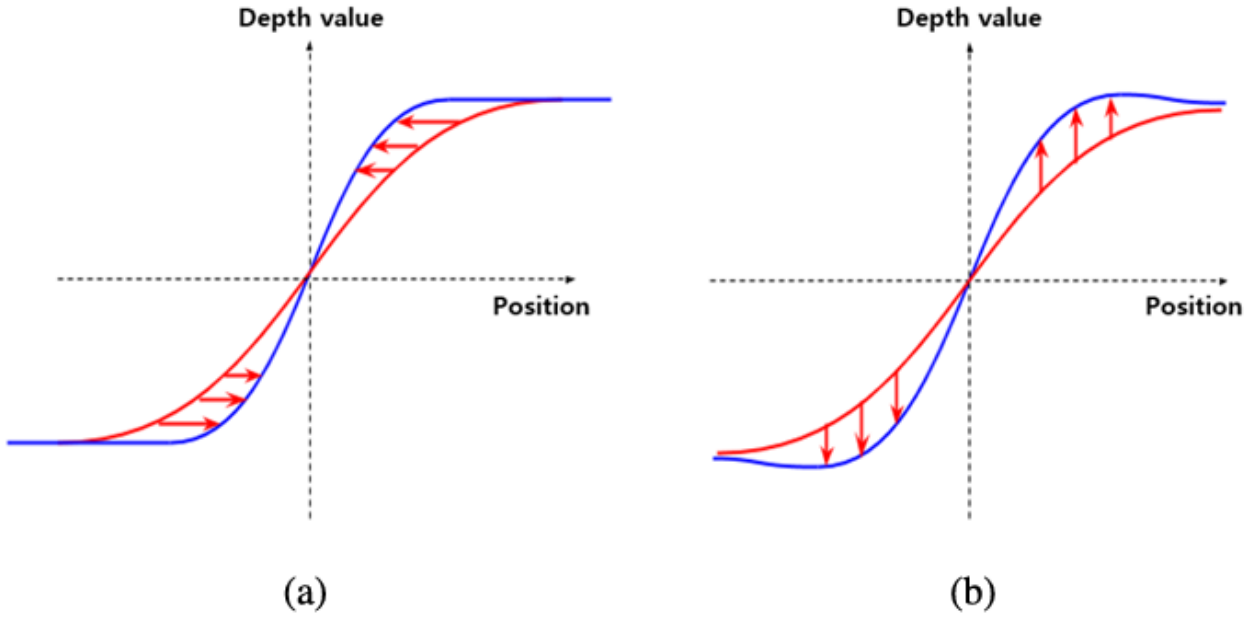

Grid warping в 2D

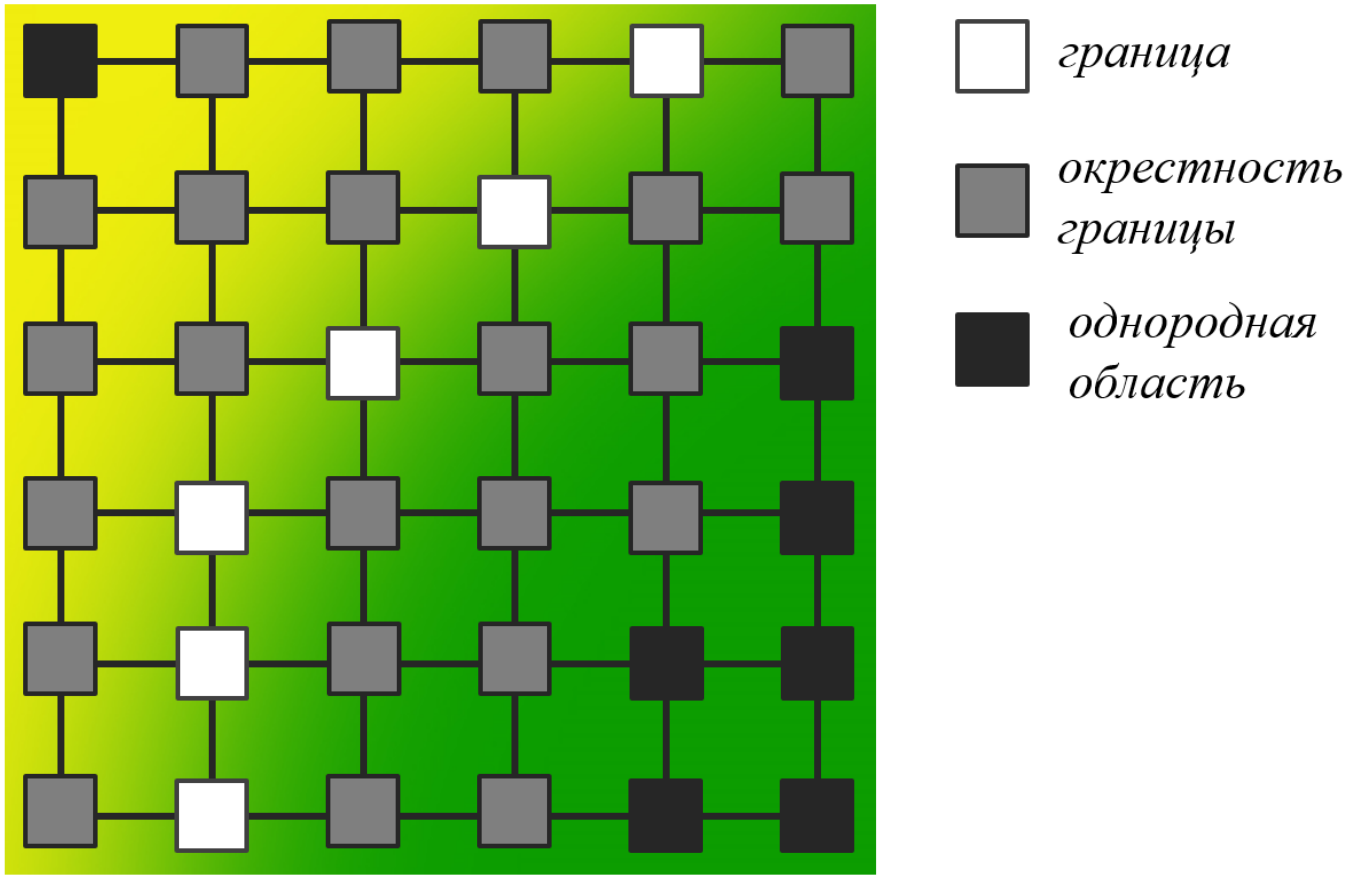

Grid warping в 2D

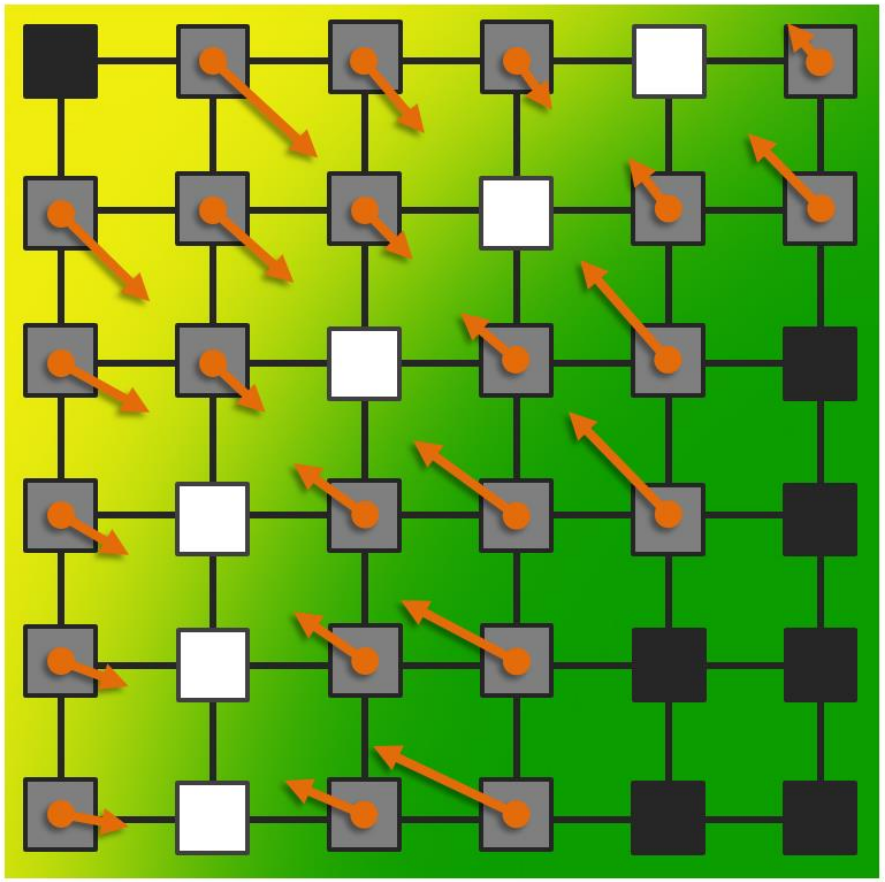

Векторное поле смещений в окрестности границы изображения

Grid warping в 2D

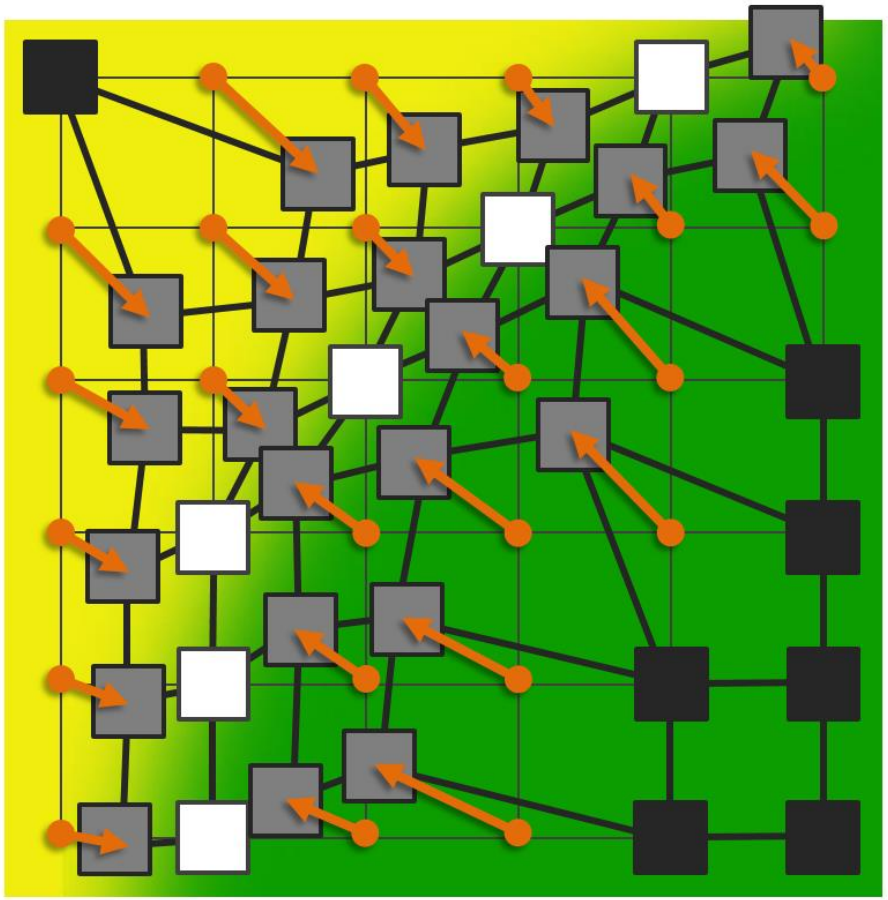

$\vec{v}$ *Векторное поле смещений в окрестности границы изображения*

Grid warping в 2D

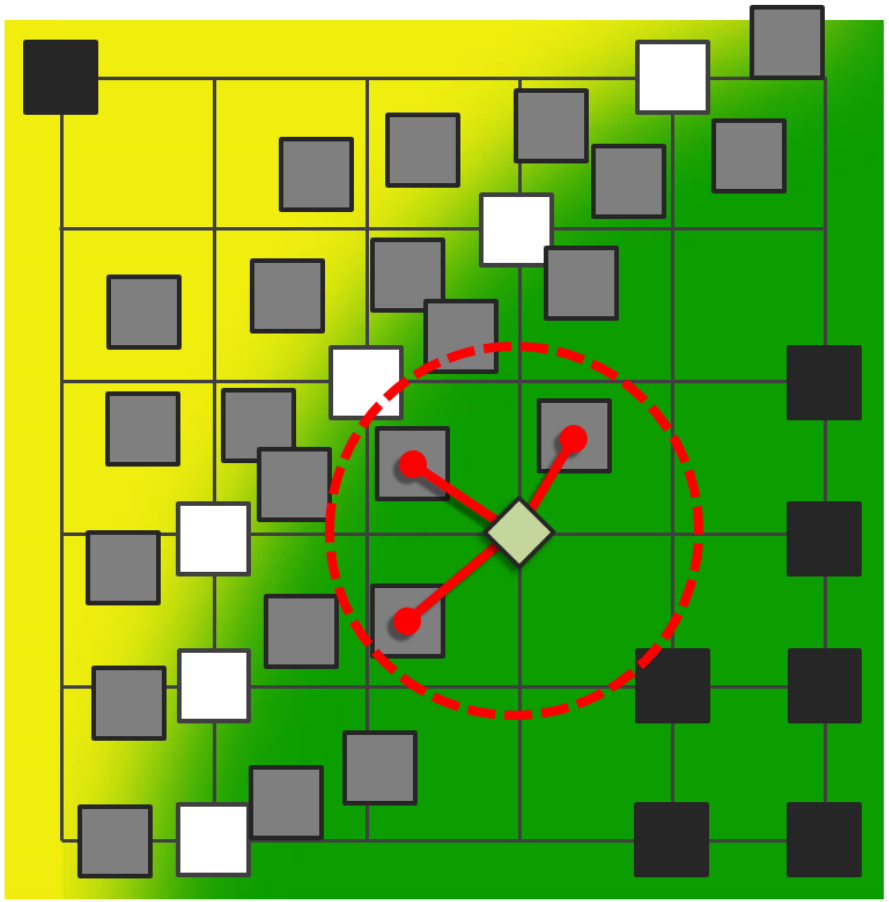

Интерполяция:

$$I_s(i,j) = \sum_{k=1}^{K} \frac{1}{D_k} I(x_k, y_k)$$

$$\{(x_k, y_k) : \rho_k \le r\}_{k=1}^{K}$$

$$\rho_k = \sqrt{(i - x_k)^2 + (j - y_k)^2}$$

$$D_k = \frac{\rho_k}{\sum_{l=1}^{K} \rho_l}$$

$$r = 1{,}5$$

Grid warping в 2D

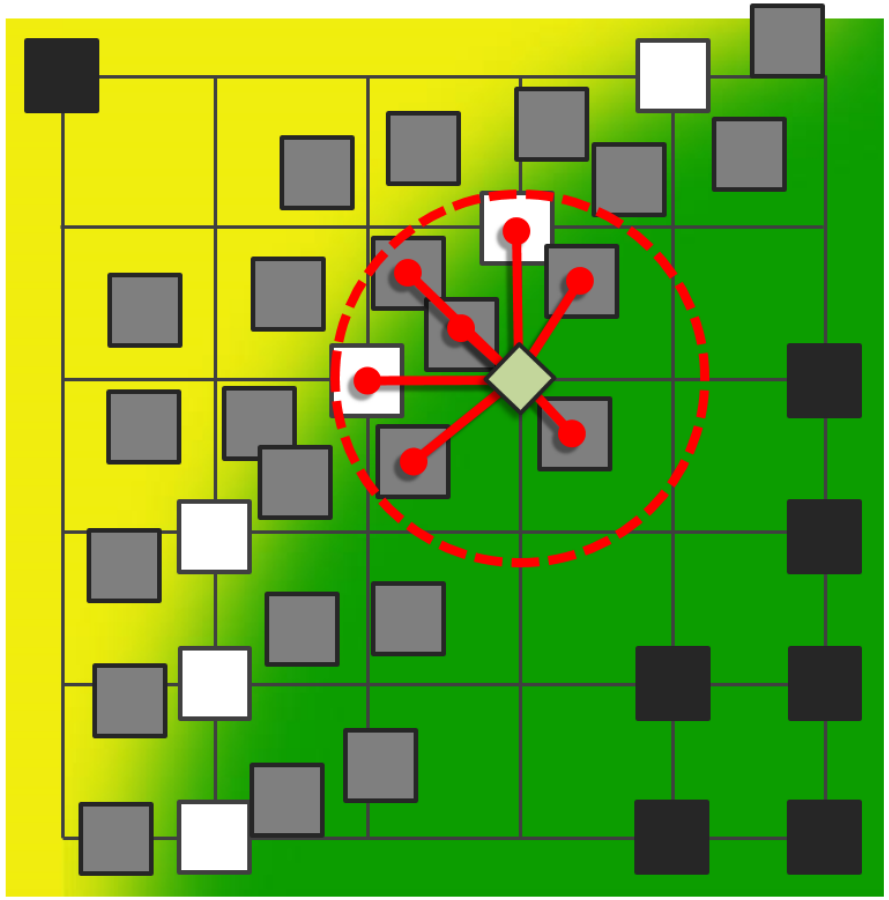

Интерполяция:

$$I_s(i,j) = \sum_{k=1}^{K} \frac{1}{D_k} I(x_k, y_k)$$

$$\{(x_k, y_k) : \rho_k \le r\}_{k=1}^{K}$$

$$\rho_k = \sqrt{(i - x_k)^2 + (j - y_k)^2}$$

$$D_k = \frac{\rho_k}{\sum_{l=1}^{K} \rho_l}$$

$$r = 1{,}5$$

Нахождение вектора смещения в 1D

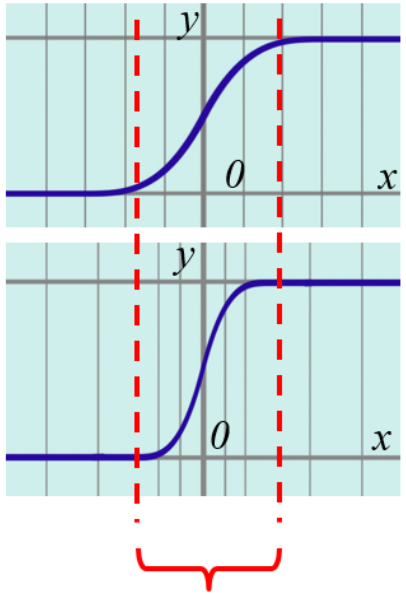

$E(x)$

$F(x)$

область деформации

$$E(x) = F(x + d(x))$$

функция сдвига

Требования:

- Монотонность сдвига

$$|x_1 + d(x_1)| \le |x_2 + d(x_2)| \text{ при } |x_1| < |x_2|$$

$$\Rightarrow \boxed{d'(x) \ge -1}$$

- Локализованность

$$\boxed{d(x) \to 0, d'(x) \to 0, x \to \infty}$$

Нахождение вектора смещения в 1D

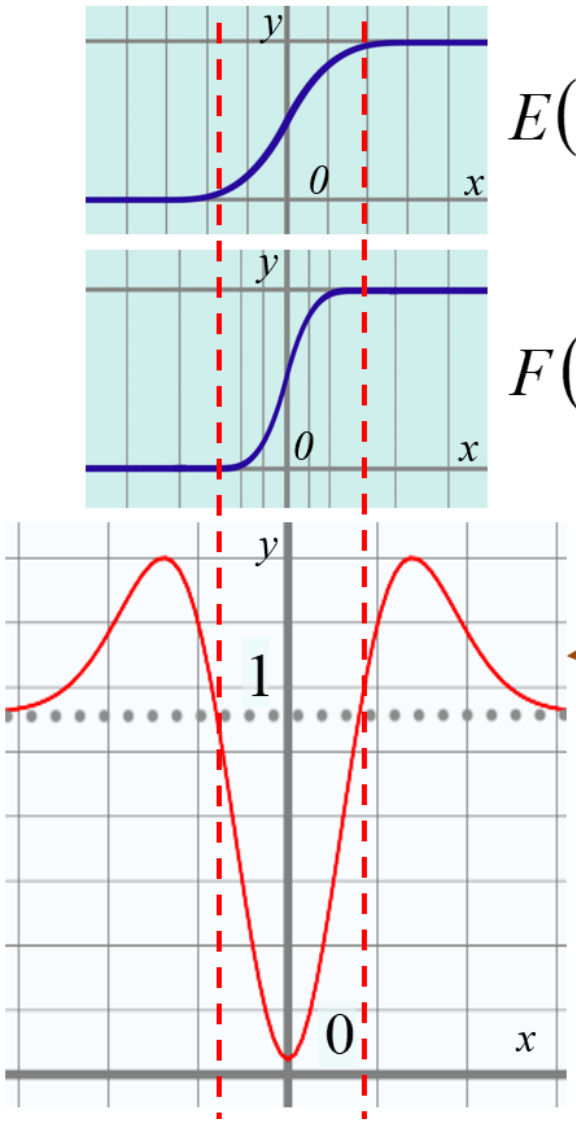

$E(x)$

$F(x)$

$$E(x) = F(x + d(x))$$

функция сдвига

Функция сдвига находится при помощи **функции близости**

$$p(x) = 1 + d'(x)$$

$$\Rightarrow \boxed{d(x) = \int_{-\infty}^{x} (p(\tau) - 1)\, d\tau}$$

Используется

$$p(x) = 1 + A G''_{\sigma}(x),$$

A - сила деформации

Нахождение вектора смещения в 2D

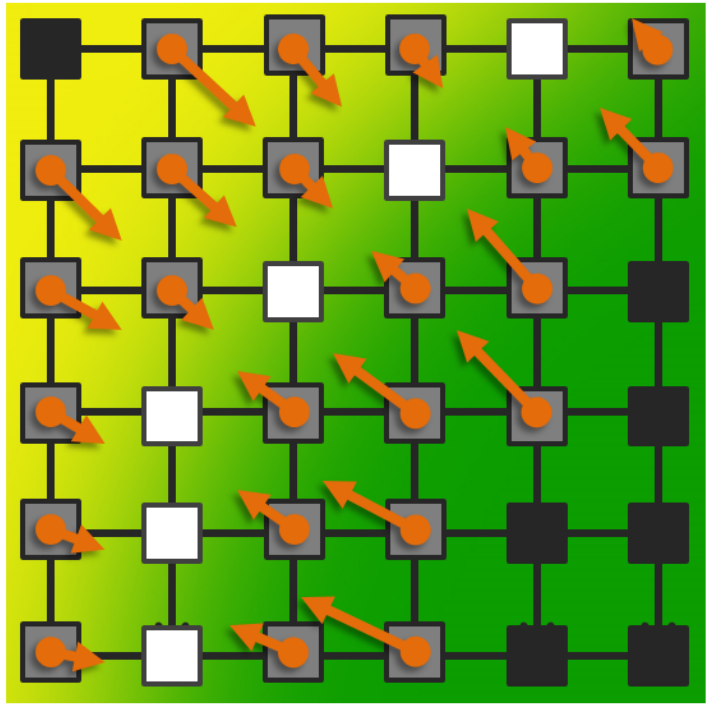

Используется одномерная функция сдвига:

$$d(x) = AG'_\sigma(x)$$

$$\boxed{\begin{aligned} &|\vec{v}| = d(\rho) \\ &\vec{v} \parallel \nabla I(x_e, y_e) \end{aligned}}$$ (в сторону границы)

$$\rho = \sqrt{(x - x_e)^2 + (y - y_e)^2},$$

(x_e, y_e) – ближайший пиксель границы

$(x,y): \rho \le 3\sigma$

σ – ширина границы

Векторное поле смещений в окрестности границы изображения

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

- Displacement Network: оценивает векторы смещения на каждой позиции пикселя, используя цветное изображение (HD) в качестве ориентира
- Fusion Network: реконструирует карту глубины высокого разрешения, используя переданные вектора смещения

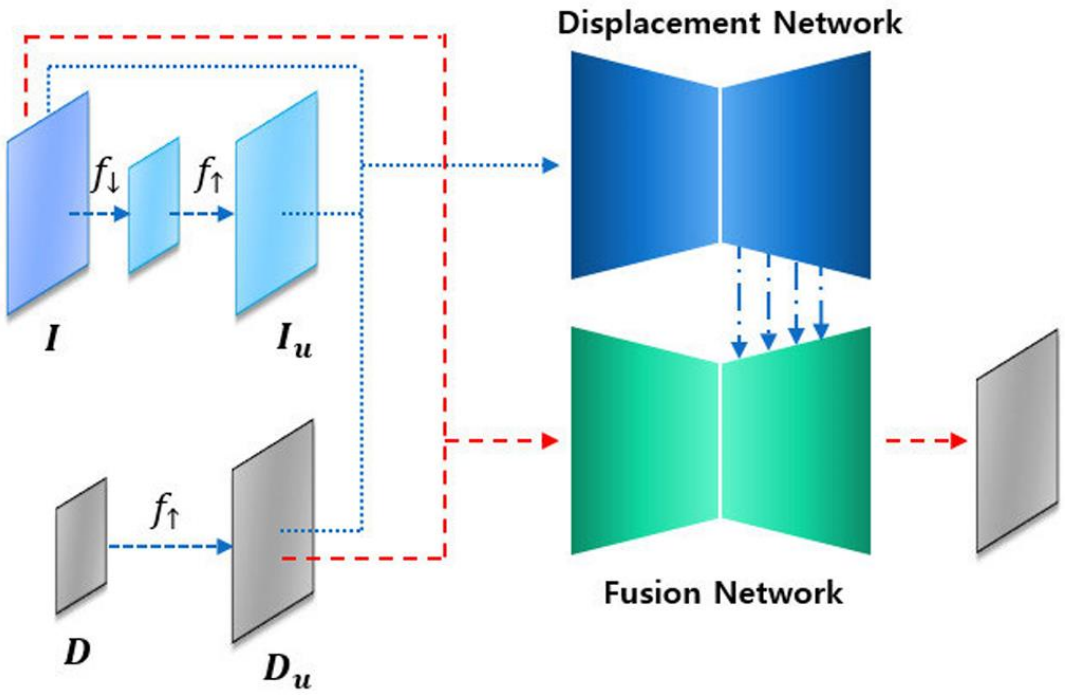

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

- Основываясь на предположении о том, что:

$$\hat{I}(x) = I_b(x + d(x))$$

- Вектор смещения $\hat{d}(x)$ можно найти как:

$$\hat{d}(x) = \arg\min_{d(x)} \|I_u(x + d(x)) - I(x)\|^2$$

- где $I_u(x) = f_{\uparrow}(f_{\downarrow}(I(x)))$ – размытое цветное изображение
- Искомую карту глубины можно найти как:

$$\hat{D}(x) = D_u(x + \hat{d}(x)) \quad where \;\; D_u = f_{\uparrow}(D)$$

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

- Displacement network
  - Основана на архитектуре FlowNetS, используемой для оценки оптического потока
  - Принимает на вход изображение высокого разрешения и его размытое представление
- Fusion network
  - Принимает на вход размытое изображение глубины и вычисленные вектора смещения
  - Использует STN для перемещения пикселей согласно рассчитанным векторным полям

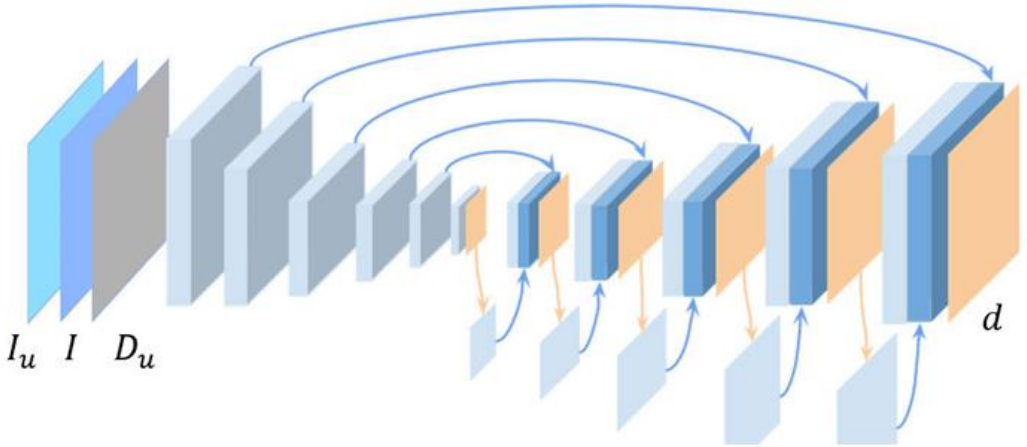

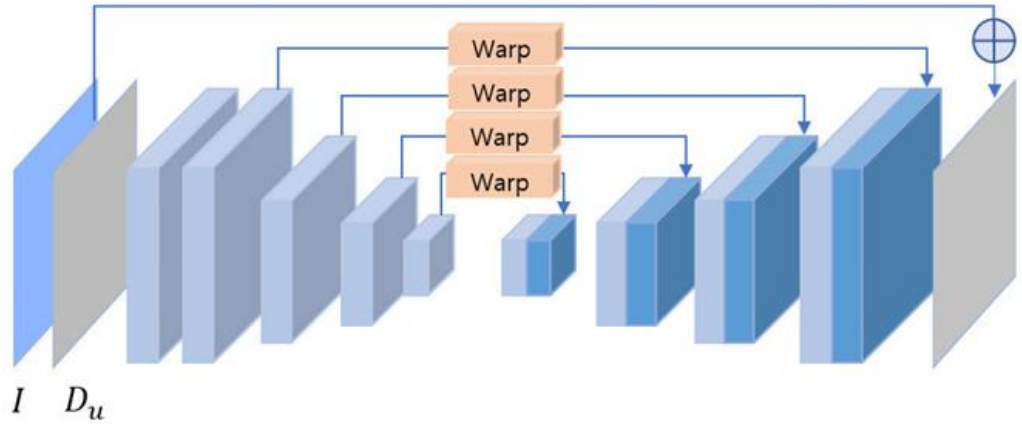

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

TABLE 1. **Quantitative performance comparisons in terms of RMSE.**

Dataset	Lu				NYU v2				Sintel				Middlebury			
Methods	2×	4×	8×	16×	2×	4×	8×	16×	2×	4×	8×	16×	2×	4×	8×	16×
BF [32]	2.953	3.423	5.398	22.013	1.666	2.378	6.970	21.209	3.460	4.347	5.877	18.692	2.173	2.978	4.368	17.161
JBU [19]	2.247	3.838	5.829	8.495	1.368	2.623	4.975	8.252	3.261	4.415	5.951	8.388	1.908	3.104	4.796	7.630
ADF [23]	1.605	3.500	8.960	9.562	1.141	2.000	6.836	8.394	4.485	9.725	20.150	17.884	1.668	2.694	4.201	7.089
NAF [3]	2.228	3.798	5.741	8.370	1.268	2.411	4.472	7.129	3.239	4.407	5.861	8.230	1.768	2.862	4.404	6.950
WMF [27]	3.752	3.742	6.056	22.213	1.942	2.648	7.286	21.258	3.755	4.685	6.253	18.798	2.568	3.286	4.826	17.240
EGF [12]	2.063	3.576	6.073	10.846	1.222	2.501	4.512	7.294	3.665	6.249	9.333	12.859	1.759	3.280	6.157	9.236
CJGF [40]	2.327	2.263	3.625	7.444	1.663	2.014	3.244	5.441	3.537	4.207	5.422	7.594	1.936	2.255	3.597	6.302
DJF [21]	1.161	2.393	3.938	6.784	1.181	1.728	2.595	4.859	2.710	3.619	4.879	7.914	1.115	1.822	3.323	6.197
PAC [36]	1.022	1.386	3.417	6.012	0.869	1.520	2.746	4.317	2.554	3.722	5.419	7.500	1.009	1.609	3.543	5.742
DBPN [9]	1.036	1.509	3.320	6.230	0.729	1.385	2.952	4.778	1.383	3.524	5.351	7.668	0.985	1.446	3.017	5.564
DKN [17]	0.734	1.135	2.419	6.100	0.660	1.080	1.911	3.522	1.367	2.916	4.546	5.770	0.984	1.317	2.349	4.492
Ours	**0.465**	**1.036**	**2.241**	**5.089**	**0.498**	**0.912**	**1.602**	**3.179**	**0.986**	**2.664**	**3.806**	**4.920**	**0.818**	**1.270**	**2.073**	**4.063**

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

TABLE 2. **Quantitative performance comparisons in terms of MAE.**

Dataset	Lu				NYU v2				Sintel				Middlebury			
Methods	2×	4×	8×	16×	2×	4×	8×	16×	2×	4×	8×	16×	2×	4×	8×	16×
BF [32]	0.804	0.866	1.271	5.485	0.556	0.698	1.510	4.885	0.416	0.488	0.678	3.114	0.856	1.056	1.512	4.927
JBU [19]	0.597	1.043	1.852	3.537	0.425	0.817	1.748	3.411	0.327	0.563	0.997	1.922	0.734	1.139	1.828	3.235
ADF [23]	0.376	0.943	2.067	4.453	0.292	0.648	2.039	3.304	0.434	1.573	6.205	5.143	0.562	1.013	1.777	3.486
NAF [3]	0.573	1.005	1.796	3.463	0.413	0.778	1.578	2.975	0.330	0.561	0.951	1.704	0.693	1.058	1.687	2.955
WMF [27]	0.557	0.636	1.347	5.732	0.413	0.613	1.622	4.965	0.216	0.339	0.631	3.111	0.771	1.013	1.593	4.978
EGF [12]	0.252	0.596	1.314	3.321	0.266	0.631	1.309	2.704	0.313	0.627	1.231	2.251	0.533	1.009	2.014	3.605
CJGF [40]	0.279	0..406	0.925	2.305	0.307	0.542	1.096	2.258	0.248	0.446	0.766	1.540	0.574	0.802	1.390	2.760
DJF [21]	0.768	0.829	1.250	2.617	0.727	0.851	1.176	2.362	0.834	1.023	1.189	2.539	0.700	0.990	1.600	3.202
PAC [36]	0.322	0.536	1.445	2.896	0.318	0.630	1.289	2.356	0.396	0.722	1.502	2.621	0.514	0.813	1.804	3.241
DBPN [9]	0.229	0.543	1.233	2.524	0.206	0.550	1.243	2.296	0.075	0.476	1.032	2.097	0.438	0.686	1.297	2.741
DKN [17]	0.103	0.240	**0.599**	1.971	0.166	0.368	0.748	1.673	0.083	0.309	0.781	1.340	0.415	0.587	0.968	2.117
Ours	**0.070**	**0.231**	0.601	**1.616**	**0.134**	**0.329**	**0.633**	**1.484**	**0.060**	**0.283**	**0.531**	**0.975**	**0.383**	**0.583**	**0.924**	**1.926**

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

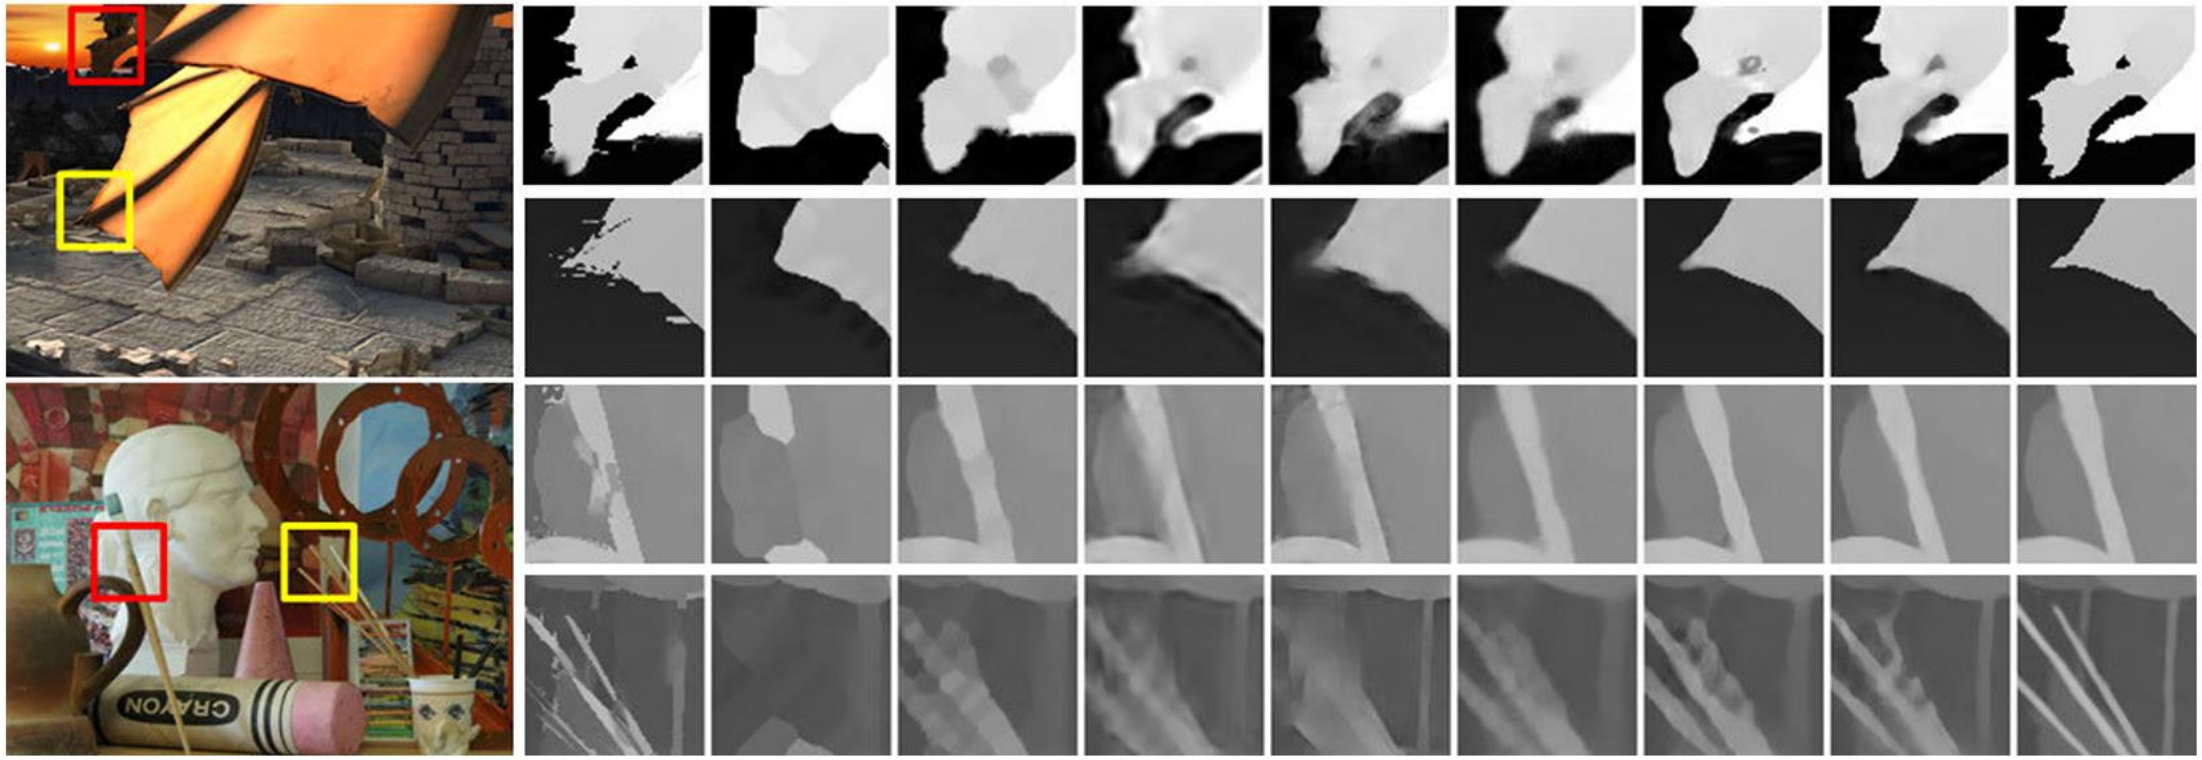

FIGURE 4. Visual comparisons for the 8× upsampled *Lu*, *Temple 3*, *Temple 2*, and *Art* depth maps by various methods: BF [32], EGF [12], CJGF [40], DJF [21], PAC [36], DBPN [9], DKN [17], Ours, and ground-truth (from left to right).

Deep Convolutional Grid Warping Network for Joint Depth Map Upsampling

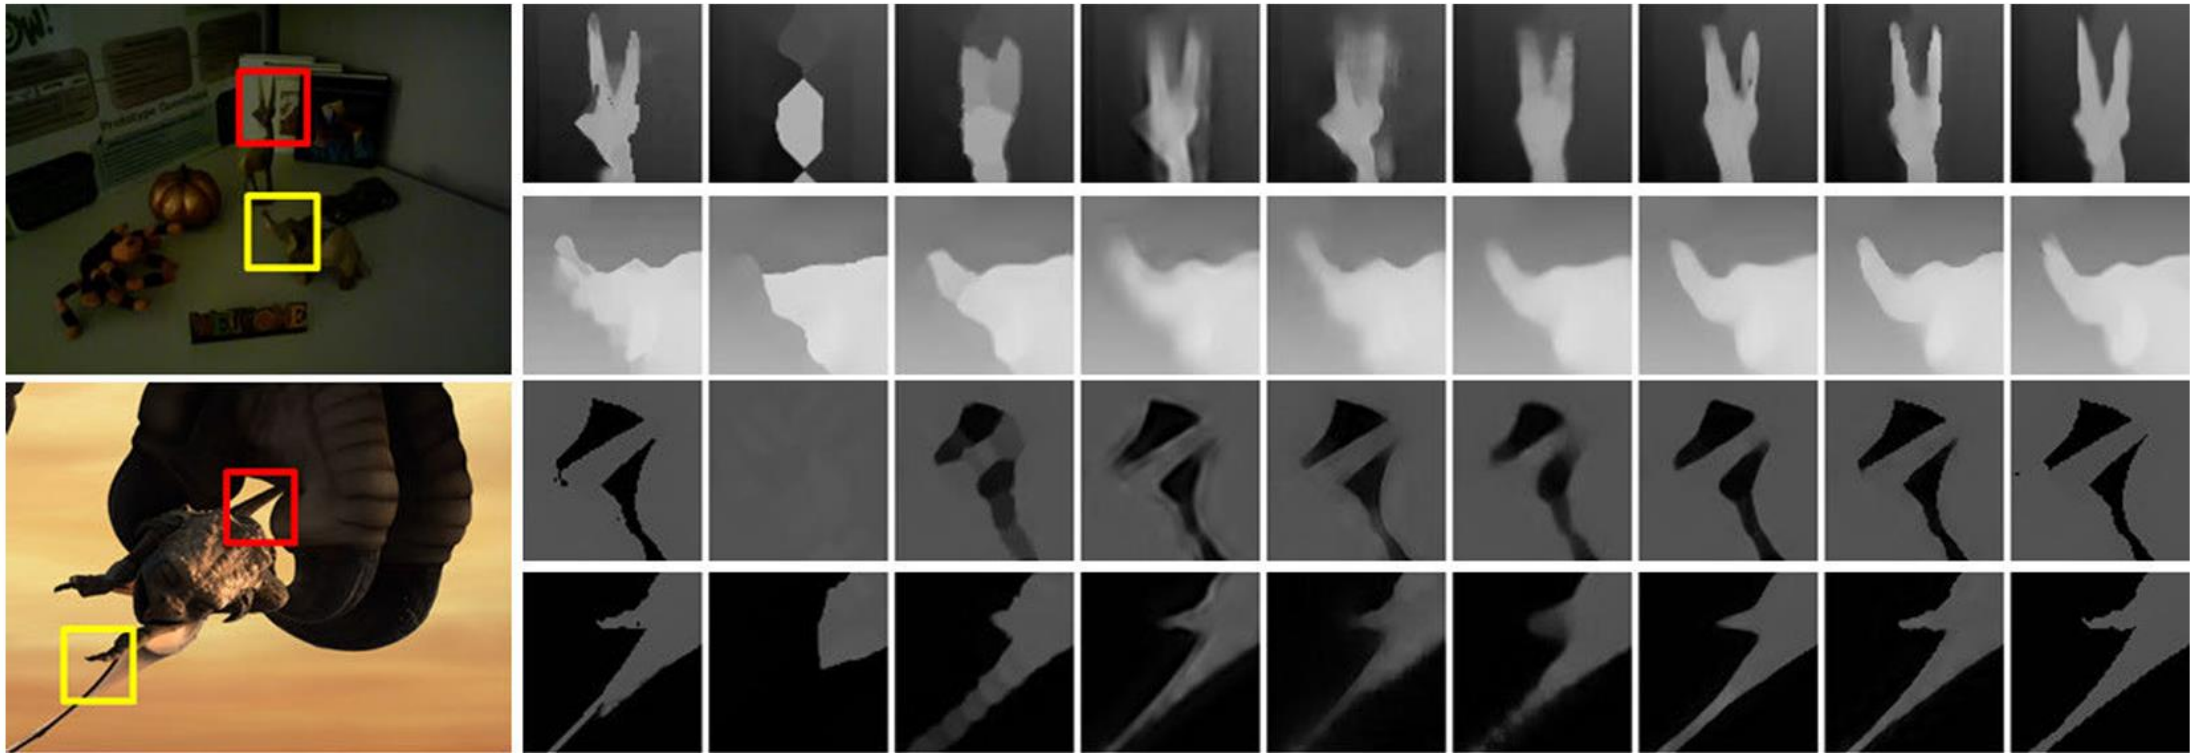

FIGURE 4. Visual comparisons for the 8× upsampled *Lu*, *Temple 3*, *Temple 2*, and *Art* depth maps by various methods: BF [32], EGF [12], CJGF [40], DJF [21], PAC [36], DBPN [9], DKN [17], Ours, and ground-truth (from left to right).