

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ М. В. ЛОМОНОСОВА
ФАКУЛЬТЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ
КАФЕДРА МАТЕМАТИЧЕСКОЙ ФИЗИКИ

Новикова Вера Дмитриевна

Метод оценки качества радиологических отчетов

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель:
профессор, д.ф.-м.н.
Крылов Андрей Серджевич

Москва, 2026

Оглавление

Введение 3
1 Постановка задачи 5
2 Обзор существующих решений 6
2.1 Общие NLG-подходы 6
2.2 Подходы к оценке медицинских отчётов 9
2.3 Подходы к оценке на основе больших языковых моделей 10
3 Предлагаемый метод 12
3.1 Общая идея подхода 12
3.2 Подготовка данных и построение русскоязычного набора данных . . . 13
3.3 Базовые компоненты предлагаемого подхода 14
3.4 Кросс-валидация 20
4 Результаты 24
4.1 Конфигурация экспериментов 24
4.2 Количественные результаты 24
4.3 Дальнейшее развитие 26
5 Заключение 28

Список литературы **29**

Введение

В последние годы наблюдается устойчивый рост интереса к системам автоматической генерации радиологических отчётов на основе изображений медицинских исследований. Современные модели, в том числе трансформерные и мультимодальные архитектуры, демонстрируют всё более высокое качество в задачах генерации клинически осмысленных описаний снимков и рассматриваются как средство снижения нагрузки на специалистов и повышения единообразия отчётности [1—3]. Эти системы позволяют ускорять работу врачей, автоматизировать рутинные части описания и улучшать коммуникацию между специалистами.

Ключевым ограничением для практического внедрения таких систем остаётся надёжная автоматическая оценка качества генерируемых отчётов. Традиционные подходы к оценке текстов, основанные на совпадении N-грамм (последовательностей из N слов) или общем языковом сходстве, плохо отражают клиническую корректность: отчёт, в котором меняется лишь отрицание критически важного признака, может получить высокий балл, хотя с точки зрения врача это серьёзная ошибка. Недавние работы подчёркивают, что подходы к оценке в радиологии должны быть чувствительны к фактическим ошибкам и коррелировать с экспертной разметкой, иначе сравнение моделей и отслеживание прогресса в области генерации радиологических отчётов становится ненадёжным [2].

Для решения этой проблемы появляются специализированные подходы к оценке, использующие клинически информативные представления отчёта. К таким подходам относятся использование векторного представления меток CheXbert для сравнения извлечённых из отчётов патологий [2, 4], а также схему извлечения сущностей и отношений RadGraph, в которой отчёты преобразовываются в граф клинических объектов связей между ними [5]. На основе таких представлений можно вычислять показатели совпадения между отчётами, уже непосредственно соотнесённые с клиническими находками, а не с поверхностным лексическим сходством.

Параллельно развиваются методы оценки, опирающиеся на большие языковые модели (large language models, LLM). Подход GREEN использует языковую модель для детального описания и подсчёта клинически значимых и незначимых ошибок в автоматически сгенерированном отчёте-кандидате относительно эталонного отчёта, предлагая количественную оценку и интерпретируемые текстовые объяснения [6]. FineRadScore, в свою очередь, формулирует задачу как минимальное число строковых правок, необходимых для превращения отчёта-кандидата в эталонный отчёт, дополняя это оценкой серьёзности ошибок и комментариями к каждой правке [7]. Эти работы показывают, что использование больших языковых моделей позволяет строить более гибкие и интерпретируемые подходы к оценке качества отчётов.

Таким образом, существует острая потребность в разработке специализированного подхода к оценке качества русскоязычных радиологических отчётов, учитывающего особенности языка предметной области и структуру клинических заключений. Целью данной работы является разработка метода оценки качества радиологических отчётов органов груд-

ной клетки на русском языке, который, в отличие от подходов, опирающихся только на текстовое сравнение, учитывает как соответствие отчёта эталонному описанию, так и его согласованность с визуальными данными исследования. Практическая значимость работы определяется возможностью использования предложенного подхода для сопоставления систем автоматической генерации отчётов, контроля качества их результатов и дальнейшей адаптации таких систем к русскоязычной клинической практике.

1. Постановка задачи

Задачей выпускной квалификационной работы является разработка метода оценки качества русскоязычных радиологических отчётов органов грудной клетки в условиях ограниченного объёма размеченных данных.

Особенность рассматриваемой задачи состоит в том, что для русскоязычной медицинской предметной области объём доступных данных слишком мал для обучения полноценной специализированной модели оценки качества. В связи с этим в работе предлагается не обучение новой модели с нуля, а построение метода, основанного на комбинировании существующих текстовых, визуально-текстовых и клинически-ориентированных методов оценки с автоматическим подбором их конфигурации и весов на обучающей выборке.

В рамках задачи можно выделить несколько подзадач:

1) Изучение существующих методов оценки качества радиологических отчётов и выбор набора базовых подходов, пригодных для адаптации к использованию на русском языке.

2) Формирование экспериментального набора данных для оценки качества русскоязычных радиологических отчётов.

3) Разработка метода, комбинирующего базовые методы оценки, методику их выбора и смешивания результатов.

4) Программная реализация предложенного подхода.

5) Анализ полученных результатов, сравнение с отдельными базовыми способами оценки и интерпретация качества итогового метода с точки зрения согласованности с врачебной оценкой.

2. Обзор существующих решений

На данный момент существует много способов оценки качества автоматически сгенерированного текста. В литературе по генерации текстов, включая радиологические отчёты, традиционно используются общие методы оценки из области генерации естественного языка (natural language generation, NLG), заимствованные из машинного перевода. К ним относятся BLEU, METEOR, ROUGE, CIDEr, SPICE и BERTScore [8—13]. Более поздние обзоры, посвященные медицинским текстам, дополняют их специализированными подходами на основе структурированных представлений содержимого отчёта: RadGraph F1, векторное представление CheXbert (SembScore), RadCliQ, RaTEScore, а также методы оценки на основе больших языковых моделей, такие как GREEN и FineRadScore [2, 4—7, 14].

2.1. Общие NLG-подходы

BLEU. Bilingual Evaluation Understudy (BLEU) – один из первых и наиболее распространенных до сих пор методов оценки качества машинного перевода [8]. Он опирается на модифицированную точность N-грамм p_n между отчётом-кандидатом и эталонными описаниями. Для каждого порядка N она определяется как

$$p_n = \frac{\sum\limits_{g \in \mathcal{G}_n} \min\bigl(\mathrm{count}_{\mathrm{cand}}(g),\ \mathrm{count}_{\mathrm{ref}}(g)\bigr)}{\sum\limits_{g \in \mathcal{G}_n} \mathrm{count}_{\mathrm{cand}}(g)},$$

где $\mathcal{G}_n$ – множество всех N-грамм, встречающихся в кандидате; $\mathrm{count}_{\mathrm{cand}}(g)$ – число вхождений N-граммы g в кандидате, а $\mathrm{count}_{\mathrm{ref}}(g)$ – «обрезанная» частота, равная числу вхождений g в эталонный текст.

Итоговый балл вычисляется как взвешенное геометрическое среднее этих точностей с учётом штрафа за краткость:

$$\mathrm{BLEU} = \mathrm{BP} \cdot \exp\left(\sum_{n=1}^{N} w_n \log p_n\right),$$

где BP – штраф за краткость, $\mathrm{BP} = 1$ при $c > r$ и $\mathrm{BP} = \exp(1 - r/c)$ иначе; c и r – суммарные длины кандидатов и эталонов соответственно.

Данный подход работает очень быстро и применим к любому языку. Однако у него есть ряд ограничений: в методе BLEU учитываются только точные совпадения в формулировках, а не семантика текста, и поэтому два текста, одинаковых по смыслу, но сформулированных по-разному, могут получить низкую оценку. Для исправления этих недостатков были предложены более поздние методы.

ROUGE. Семейство методов ROUGE [10] было разработано для оценки систем автоматического реферирования. В изученных работах чаще всего применяется ROUGE-L, основанный на длине наибольшей общей подпоследовательности между эталонным и сгенерированным текстами. Пусть $LCS(X, Y)$ – длина наибольшей общей подпоследовательности

для двух последовательностей слов X и Y, тогда

$$P_{\text{LCS}} = \frac{LCS(X,Y)}{|X|}, \qquad R_{\text{LCS}} = \frac{LCS(X,Y)}{|Y|},$$

где $|X|$ и $|Y|$ обозначают длину последовательностей (число слов в эталонном и сгенерированном тексте соответственно). Итоговый балл задается F-мерой:

$$F_{\text{LCS}} = \frac{(1+\beta^2)P_{\text{LCS}}R_{\text{LCS}}}{R_{\text{LCS}} + \beta^2 P_{\text{LCS}}},$$

где $\beta \geqslant 0$ – гиперпараметр, задающий относительный вес полноты по сравнению с точностью. ROUGE учитывает полноту, а не только точность, в отличие от BLEU, однако также неспособен оценивать смысл текста.

METEOR. METEOR [9] также исходит из совпадений слов, но сначала строит выравнивание между сгенерированным и эталонным текстами (с учётом стемминга (нахождения корня слова) и синонимов), после чего вычисляет точность P и полноту R по униграммам. Гармоническое среднее задается с большим весом полноты:

$$F_{\text{mean}} = \frac{10PR}{R + 9P},$$

а затем вводится штраф за фрагментацию Penalty:

$$\text{Penalty} = 0.5\left(\frac{\#\text{chunks}}{\#\text{unigrams_matched}}\right)^3,$$

зависящий от числа непрерывных последовательностей совпавших слов (chunks).

Итоговое значение определяется как

$$\text{METEOR} = F_{\text{mean}} \cdot (1 - \text{Penalty}).$$

Данный метод лучше коррелирует с человеческой оценкой, чем рассмотренные ранее методы, однако все ещё неспособен в полной мере учесть смысловое наполнение текстов.

CIDEr. Подход CIDEr (Consensus-based Image Description Evaluation) был предложен для оценки описаний изображений (image captioning) и измеряет степень согласованности описания-кандидата с набором эталонных описаний одного и того же изображения [11]. Для повышения чувствительности к содержательно важным словам используется TF–IDF-взвешивание N-грамм; наиболее частые, малоинформативные N-граммы получают меньший вес.

Рассмотрим изображение i с описанием-кандидатом c_i и набором эталонных описаний $S_i = \{s_{ij}\}_{j=1}^{m}$. После стемминга для каждого $N \in \{1,2,3,4\}$ каждое предложение представляется набором N-грамм $\{w_k\}$. Пусть $h_k(s_{ij})$ и $h_k(c_i)$ обозначают количество появлений N-граммы w_k в s_{ij} и c_i соответственно. Тогда для предложения s_{ij} определим компоненту TF–IDF для N-граммы w_k как

$$g_k(s_{ij}) = \underbrace{\frac{h_k(s_{ij})}{\sum\limits_{w_l} h_l(s_{ij})}}_{\text{TF}} \cdot \underbrace{\log \frac{|I|}{\sum\limits_{p=1}^{|I|} \mathbb{I}\left[\sum\limits_j h_k(s_{pj}) > 0\right]}}_{\text{IDF}},$$

где $|I|$ – количество изображений в корпусе, а индикатор $\mathbb{I}[\cdot]$ показывает, встречается ли N-грамма w_k хотя бы в одном эталонном описании изображения p. Аналогично вычисляется $g_k(c_i)$ для описания-кандидата. Затем для данного n вычисляется среднее косинусное сходство кандидата с эталонными описаниями:

$$\mathrm{CIDEr}_n(c_i, S_i) = \frac{1}{m} \sum_{j=1}^{m} \frac{g_n(c_i) \cdot g_n(s_{ij})}{\|g_n(c_i)\| \|g_n(s_{ij})\|}.$$

Итоговый балл CIDEr для изображения i определяется как взвешенная сумма по различным длинам N-грамм:

$$\mathrm{CIDEr}(c_i, S_i) = \sum_{n=1}^{N} w_n \mathrm{CIDEr}_n(c_i, S_i),$$

где в исходной работе обычно берут $N = 4$ и равные веса w_n.

Использование TF–IDF позволяет понижать вклад часто встречающихся N-грамм и усиливать вклад более информативных выражений. Однако для хорошей работы данный подход требует большого количества эталонных текстов, а также не полностью учитывает семантическую близость текстов.

SPICE. Метод оценки SPICE [12] также применяется в области image captioning. Он оценивает семантическое содержимое текстов: кандидатное и эталонные описания переводятся в графы сцены, в которых узлы соответствуют объектам, атрибутам и отношениям между ними. Из этих графов извлекаются множества логических кортежей $T(c)$ и $T(r)$, далее рассчитываются точность и полнота:

$$P = \frac{|T(c) \cap T(r)|}{|T(c)|}, \quad R = \frac{|T(c) \cap T(r)|}{|T(r)|},$$

а итоговый балл – стандартная F-мера:

$$\mathrm{SPICE}(c, r) = \frac{2PR}{P + R}.$$

Недостатком этого метода является то, что для корректного его использования необходима грамматическая и синтаксическая корректность оцениваемых предложений.

BERTScore. Подход BERTScore [13] использует векторные представления токенов, полученных из предобученной языковой модели BERT. Пусть $x = \langle x_1, \ldots, x_m \rangle$ и $y = \langle y_1, \ldots, y_n \rangle$ – эталон и кандидат, а $\mathbf{r}_i$ и $\mathbf{c}_j$ – их векторные представления. Определим матрицу косинусных сходств $s_{ij} = \cos(\mathbf{c}_j, \mathbf{r}_i)$. Тогда

$$P = \frac{1}{n} \sum_{j=1}^{n} \max_i s_{ij}, \qquad R = \frac{1}{m} \sum_{i=1}^{m} \max_j s_{ij},$$

и итоговая оценка – F-мера

$$F_{\mathrm{BERT}} = \frac{2PR}{P + R}.$$

При необходимости значения могут дополнительно взвешиваться IDF-весами токенов для снижения влияния частых слов.

Все перечисленные NLG-подходы хорошо отражают лексическое и, частично, семантическое сходство текстов, но слабо чувствительны к клинически значимым расхождениям (например, наличию отрицания), что ограничивает их полезность для оценки радиологических отчётов.

2.2. Подходы к оценке медицинских отчётов

Далее будут рассмотрены методы оценки, специально разработанные для радиологических отчётов; именно они лежат в основе современных публичных лидербордов (рейтинговых таблиц) по генерации отчётов, таких как ReXrank [15], и используются для объективного сравнения существующих моделей.

RadGraph F1. RadGraph [5] предлагает схему разметки отчётов в виде графа клинических сущностей (патологии, анатомические структуры, модификаторы) и отношений между ними. Оценка RadGraph F1 вычисляется как F-мера между множествами сущностей и отношений, извлечённых из отчёта-кандидата и эталонного отчёта:

$$F_{\text{RadGraph}} = \frac{2P_{\text{ent/rel}}R_{\text{ent/rel}}}{P_{\text{ent/rel}} + R_{\text{ent/rel}}},$$

где $P_{\text{ent/rel}}$ и $R_{\text{ent/rel}}$ – точность и полнота по сущностям и отношениям. Такой подход напрямую сравнивает факт наличия и локализацию патологий, но опирается на точность алгоритма извлечения графа.

SembScore (косинусное сходство векторов CheXbert). В работе CheXpert [4] отчёту ставится в соответствие бинарный вектор меток патологий $y \in \{0, 1\}^K$, кодирующий наличие либо отсутствие фиксированного набора находок. Сходство между отчётом-кандидатом и эталонным отчётом оценивается по косинусному сходству их векторных представлений:

$$\text{SembScore}\left(y^{(\text{ref})}, y^{(\text{cand})}\right) = \frac{y^{(\text{ref})} \cdot y^{(\text{cand})}}{\|y^{(\text{ref})}\|\|y^{(\text{cand})}\|}.$$

Этот подход хорошо отражает согласие по фиксированному набору диагнозов, но плохо покрывает редкие патологии и детали локализации.

RaTEScore. RaTEScore [14] – трёхэтапный подход: сначала разработанная авторами модель RaTE-NER выделяет из отчёта клинические сущности $e_i = (n_i, t_i)$ с типами из множества Anatomy (анатомия), Abnormality (аномалия), Disease (заболевание), Non-Abnormality (отсутствие аномалии), Non-Disease (отсутствие заболевания). Затем названия сущностей n_i отображаются кодировщиком BioLORD [16] в векторные представления f_i, так что синонимы оказываются близкими в пространстве векторных представлений. На финальном этапе для каждой сущности кандидата выбирается наиболее близкая (по косинусному сходству) сущность эталона, совокупное сходство $S(x, \hat{x})$ вычисляется с учётом матрицы весов W по типам сущностей и штрафа p за несовпадение типов, после чего из величин $S(x, \hat{x})$ и $S(\hat{x}, x)$, интерпретируемых как аналоги точности и полноты, получается итоговый RaTEScore в форме F-меры. Модель NER обучается на наборе данных RaTE-NER, кодировщик BioLORD используется предобученный, а параметры W и p находятся по размеченному врачами набору RaTE-Eval, представленному в статье авторов метода.

Однако недостатком данного подхода является то, что он не учитывает структурные связи между сущностями, обрабатывая их как независимые элементы. Ещё одно существенное требование – необходимость совпадения числа предложений в эталонном и сгенерированном отчётах. Кроме того, RaTEScore часто недооценивает степень сходства отчётов и выдаёт заниженные значения итогового счёта [17].

RadCliQ. RadCliQ [2] – обучаемый регрессионный подход, который совмещает 4 ранее описанных метода (BLEU, BERTScore, SembScore, RadGraph F1) в единый прогноз, приближающий оценку качества отчёта по числу ошибок, выявленных радиологами. В публичной рейтинговой таблице моделей генерации радиологических отчётов ReXrank [15] данный подход используется в качестве основой оценки каждой из сравниваемых моделей.

CREPE. Метод CREPE [18] предсказывает число ошибок в нескольких категориях. На вход подаются эталонный и кандидатный отчёты, после чего пара текстов переводится в векторное представление с помощью специализированного кодировщика BiomedBERT. Поверх общего текстового представления используются несколько регрессионных голов, каждая из которых предсказывает число ошибок определённого типа. В работе рассматриваются шесть категорий ошибок: ложное указание находки, пропуск находки, неверная локализация, неверная степень выраженности, ошибочное упоминание сравнения и пропуск сравнения. Итоговая оценка CREPE получается суммированием предсказанных значений по категориям, поэтому меньшая оценка соответствует более качественному заключению.

2.3. Подходы к оценке на основе больших языковых моделей

GREEN. GREEN (Generative Radiology Report Evaluation and Error Notation) [6] использует большую языковую модель для выделения и подсчёта клинически значимых и незначимых ошибок в отчёте-кандидате относительно эталонного отчёта. Модель генерирует структурированное описание ошибок (ложные находки, пропущенные находки, ошибки локализации, ошибки степени выраженности и др.) и агрегированный балл каждой пары отчётов. В упрощенном виде эту оценку можно интерпретировать как нормализованную долю корректных клинических утверждений:

$$\text{GREEN} = \frac{N_{\text{matched findings}}}{N_{\text{matched findings}} + \sum_i N_{\text{error}_i}},$$

где N_{error_i} – число клинически значимых ошибок различных типов, выделенных моделью. Типы ошибок, выделяемых моделью:

1) Ложное указание находки (находка упомянута, но в эталоне её нет).
2) Пропуск находки (находка есть в эталоне, но отсутствует в кандидате).
3) Неверная локализация/расположение находки.
4) Неверная степень выраженности (тяжесть) находки.
5) Упоминание сравнения, которого нет в эталонном заключении.

6) Пропуск сравнения, описывающего изменения относительно предыдущего исследования.

Модель GREEN была получена путём дистилляции модели GPT-4 и содержит менее 7 миллиардов параметров, что позволяет запускать ее локально. Метод демонстрирует более высокую корреляцию с оценками радиологов по сравнению с BLEU, CIDEr, RadGraph F1 и RadCliQ, а также содержит интерпретируемые текстовые объяснения выделенных ошибок.

FineRadScore. FineRadScore [7] формулирует задачу оценки как поиск минимального числа строковых правок, необходимых для преобразования отчёта-кандидата в эталонный отчёт, с использованием большой языковой модели. Для каждой строки модель генерирует исправленный вариант, оценку серьёзности ошибки с медицинской точки зрения и поясняющий комментарий. Число правок и их серьёзность затем агрегируются в итоговый балл, убывающий при увеличении количества и тяжести выявленных ошибок. Авторы показывают, что FineRadScore хорошо согласуется с оценками радиологов как на уровне отдельных строк, так и на уровне отчёта в целом.

GEMA-Score. GEMA-Score (Granular Explainable Multi-Agent Score) [19] представляет собой многоагентную систему на основе больших языковых моделей. Метод сравнивает отчёт-кандидат и отчёт-эталон по клинически значимым аспектам, включая наличие находок, локализацию, степень выраженности и неопределённость, а также учитывает более общие характеристики текста, такие как полнота, читаемость и клиническая применимость. Итоговая оценка формируется на основе частных решений агентов и сопровождается интерпретируемым объяснением выявленных расхождений.

Согласно результатам работ [2, 6, 7, 14], наилучшее согласие с экспертными оценками в задаче оценки радиологических отчётов обычно демонстрируют подходы на основе больших языковых моделей, в частности GREEN и FineRadScore.

3. Предлагаемый метод

3.1. Общая идея подхода

Задачу автоматической оценки качества радиологических отчётов для русского языка можно охарактеризовать существенным ограничением по объёму доступных размеченных данных. В отличие от английского языка, в котором существуют как крупные корпуса рентгенологических изображений и отчётов, так и специализированные способы автоматической оценки, для русскоязычных отчётов рентгена органов грудной клетки число троек вида «изображение – отчёт – экспертная оценка качества» остаётся недостаточным для обучения полноценной специализированной модели с нуля. Дополнительную сложность создаёт высокая стоимость экспертной разметки: для получения надёжной оценки качества требуется участие врачей-рентгенологов, а сама процедура сопоставления кандидатного и эталонного заключений требует клинической интерпретации и потому требует значительных временных затрат при работе с большими корпусами.

В этих условиях целесообразно отказаться от попытки построения полностью собственного обучаемого оценщика и перейти к другому сценарию: использовать уже существующие англоязычные и мультимодальные способы оценки как базовые компоненты, а затем адаптировать их к русскоязычной задаче путём комбинирования. Такой выбор обусловлен несколькими причинами. Во-первых, он позволяет опереться на уже обученные модели и алгоритмы, в которых накоплено предметное знание о клиническом тексте и связи текста с изображением. Во-вторых, он существенно снижает требования к объёму доступной обучающей выборки, поскольку на имеющихся данных требуется не обучать новую крупную модель, а лишь подобрать наиболее подходящую конфигурацию уже существующих компонент. В-третьих, такой подход остаётся гибким по отношению к конкретному набору данных: если формат целевой оценки меняется, например, вместо числа ошибок в заключении используется бинарная экспертная оценка, то может измениться и наилучшее сочетание базовых компонент.

Исходя из этого, в работе предлагается рассматривать не один фиксированный способ оценки, а комплексный адаптивный подход, состоящий из нескольких элементов, покрывающих разные аспекты клинической корректности отчёта. В базовом варианте используются три типа компонент:

1) русскоязычная клиническая компонента, ориентированная на выявление содержательных ошибок в медицинском тексте;

2) текстовая компонента, характеризующая близость кандидатного отчёта к эталонному;

3) визуально-текстовая компонента, отражающая согласованность заключения со снимком.

Итоговая оценка качества формируется как линейная комбинация этих значений:

$$S = w_{\text{ru}} z_{\text{ru}} + w_{\text{text}} z_{\text{text}} + w_{\text{img}} z_{\text{img}},$$

где z_{ru}, z_{text} и z_{img} – нормированные значения соответствующих оценок, а веса удовлетворяют ограничениям

$$w_{\text{ru}} > 0, \quad w_{\text{text}} \geqslant 0, \quad w_{\text{img}} > 0, \quad w_{\text{ru}} + w_{\text{text}} + w_{\text{img}} = 1.$$

Следовательно, основная идея предлагаемого подхода заключается в следующем: вместо обучения нового русскоязычного оценщика с нуля строится универсальная схема из нескольких существующих компонент, после чего на обучающей выборке автоматически выбираются наиболее подходящие базовые методы и подбираются веса их смешивания. Далее качество оценивается уже не для одной фиксированной комбинации, а для всего этого адаптивного подхода в целом.

3.2. Подготовка данных и построение русскоязычного набора данных

В качестве основы для экспериментального исследования в работе использовался набор данных RadEvalX, созданный для анализа согласованности автоматических способов оценки с врачебной экспертизой в задаче генерации рентгенологических заключений [20, 21]. Этот набор данных организован по схеме сопоставления эталонного и кандидатного заключений: для каждого исследования рассматривается исходный отчёт и автоматически сгенерированный вариант, после чего врачи размечают ошибки в кандидатном тексте относительно эталона. Количество ошибок используется в качестве целевой переменной при вычислении корреляции с оцениваемыми методами.

RadEvalX построен на основе исследований из открытого набора данных IU X-Ray, представляющего собой пары рентгенограмм органов грудной клетки и соответствующих им радиологических отчётов [22]. В описании RadEvalX указано, что для аннотации были отобраны 100 исследований, для каждого из которых использовался эталонный отчёт из IU X-Ray и один автоматически сгенерированный отчёт, полученный моделью M2Tr [1]. Разметка текстов проводилась двумя сертифицированными рентгенологами, спорные случаи разрешались путём совместного обсуждения до принятия единого решения.

Таким образом, RadEvalX предоставляет экспертную оценку качества кандидатных отчётов в формате числа ошибок по заранее определенным категориям. Кроме того, ошибки разделяются на два типа по уровню клинической значимости: выделяются клинически значимые (напрямую влияющие на диагноз) и клинически незначимые (не требующие срочного медицинского вмешательства) ошибки.

В оригинальной работе авторов используются следующие категории ошибок:

1) Ложное указание находки (находка упомянута, но в эталоне её нет).

2) Пропуск находки (находка есть в эталоне, но отсутствует в кандидате).

3) Неверная локализация/расположение находки.

4) Неверная степень выраженности (тяжесть) находки.

5) Упоминание сравнения, которого нет в эталонном заключении.

6) Пропуск сравнения, описывающего изменения относительно предыдущего исследования.

7) Упоминание неопределённости, которой нет в эталоне.

8) Пропуск неопределённости, которая есть в эталоне.

В исходной версии RadEvalX тексты заключений представлены на английском языке. Поскольку целью данной работы является построение способа оценки качества именно русскоязычных радиологических отчётов, была сформирована русскоязычная версия набора данных. Для этого эталонные и кандидатные заключения были переведены на русский язык с сохранением структуры клинического описания и ключевых медицинских формулировок. Для этого в работе дополнительно использовалась таблица англо-русских терминологических соответствий, составленная по авторитетным источникам по терминологии визуализации органов грудной клетки [23, 24]. Перевод был выполнен с помощью большой языковой модели GPT-5.2 [25].

Отдельного внимания требует сопоставление текстов с изображениями. Поскольку в RadEvalX присутствуют идентификаторы исследований из IU X-Ray, для каждой записи удалось восстановить связь между парами заключений и исходными рентгенограммами грудной клетки. Итоговый набор данных представлял собой набор согласованных троек вида (изображение, эталонный отчёт, отчёт-кандидат), дополненных экспертной оценкой в виде числа ошибок двух типов по восьми категориям, а также вычисленными значениями базовых компонент оценки, используемых на следующих этапах.

3.3. Базовые компоненты предлагаемого подхода

Предлагаемый в работе способ оценки строится не на одном фиксированном подходе, а на наборе базовых компонент, каждая из которых отражает отдельную сторону качества радиологического заключения. Рассматриваемые компоненты можно разделить на три группы: русскоязычная клиническая компонента, текстовые способы сопоставления кандидатного и эталонного заключений, а также визуально-текстовые методы, учитывающие согласованность текста со снимком.

Существенная особенность рассматриваемой постановки состоит в том, что большая часть доступных и хорошо изученных инструментов была разработана для англоязычных радиологических отчётов [2, 5, 14, 26—28]. Поэтому для их использования в русскоязычном сценарии требуется дополнительный этап перевода отчётов на английский язык. В работе рассматривается несколько моделей-переводчиков:

1) TranslateGemma-12B-IT [29];

2) HY-MT1.5-7B [30];

3) Qwen3.5-9B [31].

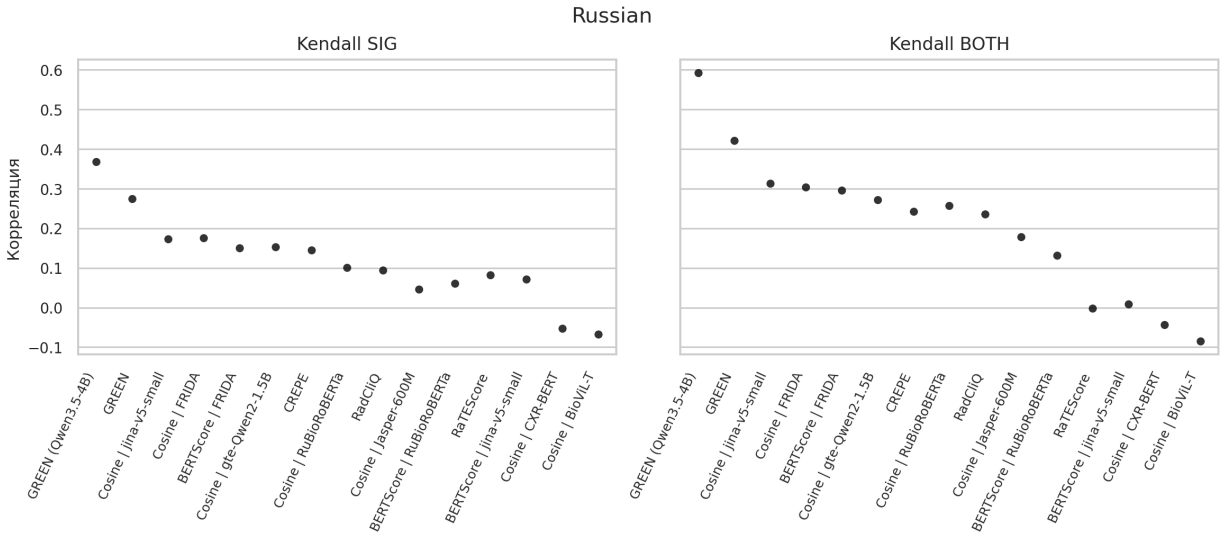
Модели HY-MT1.5-7B и Qwen3.5-9B использовались в двух режимах: без таблицы соответствия терминов и с ней. Во втором случае в текст инструкции для модели-переводчика включались элементы заранее подготовленной таблицы англо-русских терминологических соответствий, что позволяло лучше сохранять специализированную лексику, связанную с анатомией и патологическими находками. Таким образом, конкретный переводчик также становился частью общей конфигурации способа оценки.

Для иллюстрации влияния перевода на согласованность значений базовых методов с экспертной оценкой на наборе данных RadEvalX на рис. 1 приведено сравнение коэффициентов корреляции Кендалла между значениями отдельных базовых способов оценки и числом ошибок. Сравнение выполнено как для исходных русскоязычных отчётов, так и для англоязычных версий, полученных с помощью различных моделей-переводчиков и режимов использования терминологической таблицы. По данным рассматриваемого набора видно, что среди русскоязычных компонент наиболее высокая согласованность с экспертной оценкой наблюдается у подхода GREEN, тогда как среди англоязычных подходов лидирует метод на основе косинусного сходства векторных представлений, полученных при помощи кодировщика BioViL-T [27, 28], который будет подробно рассмотрен далее.

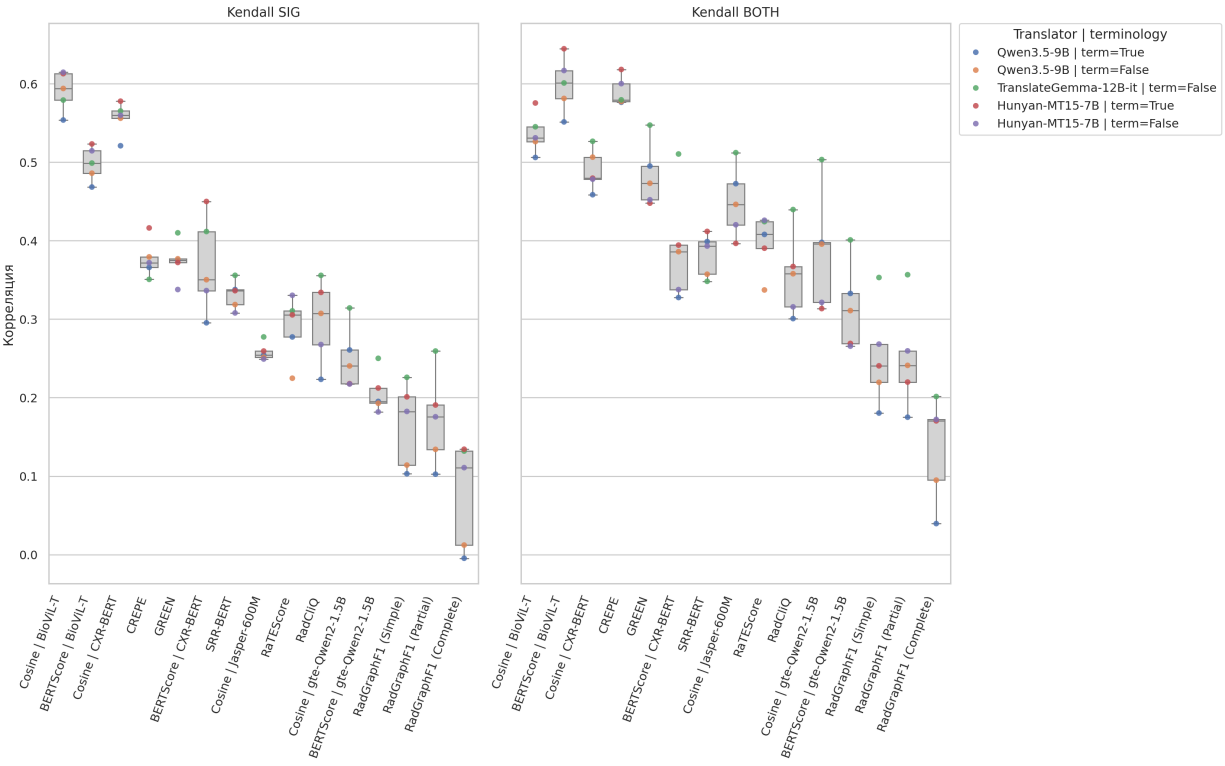
Русскоязычная клиническая компонента в работе строилась на основе подхода GREEN [6], адаптированного к русскоязычным радиологическим текстам. GREEN предназначен для сравнения кандидатного и эталонного заключений с акцентом на клинически значимые расхождения: ложные указания находок, пропуски, ошибки в локализации, степени выраженности и формулировках неопределённости. В рамках данной работы в русскоязычном варианте GREEN в качестве базовой языковой модели использовалась открытая модель Qwen3.5-9B [31] без дообучения на русскоязычных медицинских текстах. Ключевой особенностью данного решения является его интерпретируемость: помимо количественной оценки числа ошибок, метод предоставляет текстовое объяснение выявленных расхождений.

В качестве текстовых англоязычных компонент рассматривались подходы RadGraph, RadCliQ и RaTEScore, а также подходы на основе косинусной близости и BERTScore векторных представлений, полученных с помощью специализированных медицинских моделей CXR-BERT-specialized и BioViL-T [27, 28]. Подход RadGraph опирается на структурированное представление радиологического текста в виде графа сущностей и отношений [5, 26]. Для каждого заключения автоматически выделяются анатомические сущности, наблюдения и связи между ними, после чего кандидатный и эталонный тексты сравниваются на уровне совпадения клинически значимых объектов и их отношений.

Подход RadCliQ был предложен как составной показатель качества радиологических заключений, обученный так, чтобы согласоваться с экспертной оценкой рентгенологов [2]. Он объединяет несколько англоязычных методов оценки, включая лексическое сходство, контекстную близость, близость по клиническим ярлыкам и структурное совпадение по RadGraph. В исходной постановке меньшие значения RadCliQ соответствуют лучшему качеству отчёта. Для согласования направления шкалы с остальными компонентами в данной работе использовалась величина $\frac{1}{\text{RadCliQ}}$, так что большее значение означало более высокое качество заключения-кандидата.



(a) Корреляция Кендалла со значениями оценок на русском языке



(b) Корреляция Кендалла со значениями оценок на английском языке

Рис. 1: Сравнение коэффициентов корреляции Кендалла между значениями базовых оценок и числом ошибок на наборе данных RadEvalX. По оси абсцисс перечислены базовые способы оценки, по оси ординат – коэффициент корреляции Кендалла. Цветные точки соответствуют различным моделям перевода и режимам использования терминологической таблицы. Слева в каждом подрисунке приведена корреляция с числом клинически значимых ошибок (SIG), справа – с общим числом ошибок (BOTH).

Подход RaTEScore ориентирован на сравнение радиологических текстов на уровне медицинских сущностей [14]. В его основе лежит предварительное выделение сущностей из радиологического текста с последующим сопоставлением их представлений в векторном пространстве.

Векторные представления, использованные в компонентах на основе косинусной близости и BERTScore, извлекались с помощью специализированной модели CXR-BERT-specialized [27]. Она представляет собой текстовый кодировщик для радиологических текстов, построенный на основе базовой модели CXR-BERT, которая в свою очередь была обучена на специализированном словаре и корпусах предметной области. Модель CXR-BERT-specialized дополнительно обучалась в постановке согласования текста отчёта с одиночными рентгенограммами грудной клетки.

Предобучение BioViL-T выполнялось на наборе MIMIC-CXR v2 [32, 33], содержащем повторные рентгенологические исследования одних и тех же пациентов [28]. В обучающую выборку включались исследования с фронтальным снимком, для которых был доступен раздел заключения (Impression), при наличии предшествующего исследования дополнительно использовалось соответствующее предыдущее изображение. В результате формировалось объединение примеров двух типов: с одной рентгенограммой и с парой текущего и предыдущего изображений. Авторы указывают, что для предобучения было собрано 174.1 тыс. обучающих и 4.9 тыс. валидационных пар «изображение-текст», причём большая часть обучающих примеров содержала предыдущее изображение.

По своей архитектуре BioViL-T является мультимодальной моделью, где визуальный кодировщик представляет собой гибрид сверточной нейронной сети и архитектуры Transformer, а текстовый – кодировщик с архитектурой BERT, инициализированный весами базовой модели CXR-BERT [28]. На вход текстового кодировщика подается токенизированный (разбитый на токены – минимальные текстовые единицы) радиологический текст. В процессе обучения данные проходят через модель дважды: первый проход выполняется с маскированием токенов для решения задачи языкового моделирования с опорой на визуальные данные, а второй – без маскирования, для контрастивного выравнивания с визуальными представлениями. На финальном этапе текстовые и визуальные признаки отображаются в единое скрытое пространство для совместной оптимизации.

Косинусная близость рассчитывалась для векторных представлений текста заключения. Если $\mathbf{s}^{(c)}$ и $\mathbf{s}^{(r)}$ – векторные представления текста-кандидата и текста-эталона соответственно, то соответствующая оценка вычислялась как

$$\mathrm{CosSim}\left(\mathbf{s}^{(c)}, \mathbf{s}^{(r)}\right) = \frac{\left(\mathbf{s}^{(c)}\right)^{\top} \mathbf{s}^{(r)}}{\left\|\mathbf{s}^{(c)}\right\|_2 \left\|\mathbf{s}^{(r)}\right\|_2}.$$

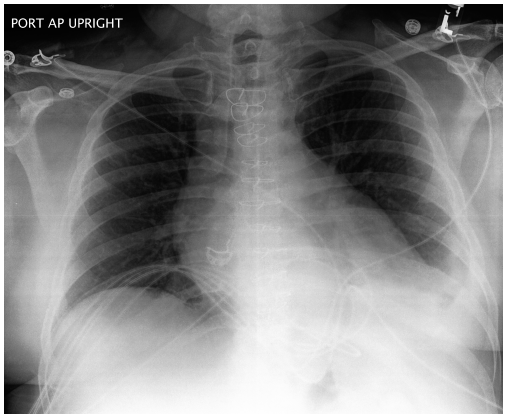
Для более детального сопоставления текстов на уровне токенов использовался подход BERTScore с использованием ранее упомянутых специализированных кодировщиков CXR-BERT-specialized и BioViL-T. В отличие от стандартной косинусной близости, оценивающей сходство текстов на макроуровне, данный метод предполагает вычисление аналогов точно-

сти и полноты за счёт нахождения наилучших попарных совпадений между контекстными векторными представлениями каждого токена кандидатного и эталонного отчётов.

Визуально-текстовые компоненты были включены в предлагаемый метод для того, чтобы итоговая оценка учитывала не только сходство с эталонным текстом, но и согласованность отчёта с изображением. Одной из таких компонент является BioViL-T [28]. Итоговая оценка сходства отчёта-кандидата с изображением получалась путём вычисления косинусной близости векторных представлений текста отчёта и снимка, полученных из кодировщика BioViL-T.

Дополнительно в рамках работы был обучен проектор, переводящий текстовые эмбеддинги, полученные моделью CXR-BERT-specialized, в общее визуально-текстовое пространство специализированного медицинского мультимодального кодировщика MedSigLIP. Для оптимизации модели использовалась попарная сигмоидная функция потерь, описанная в работе [34] (архитектура SigLIP): каждая пара «изображение-текст» внутри мини-батча рассматривалась как отдельный бинарный пример, причём согласованные пары считались положительными, а несогласованные – отрицательными.

Обучение выполнялось на наборе CheXpert Plus [35]. Данный набор данных содержит 223 462 рентгенограмм грудной клетки из 187 711 исследований 64 725 пациентов. Каждому снимку соответствует текст радиологического отчёта, разбитый на разделы с помощью автоматической разметки, а также метаданные пациента, такие как пол, возраст и т. д. Для обучения проектора использовался текст из раздела заключение (Impression), полученный после первичной фильтрации набора данных, представляющей собой удаление слишком коротких (менее 10 слов) и повторяющихся отчётов. Пример изображения и соответствующего ему раздела заключения представлен на Рис. 2.



Impression:
1. ENLARGEMENT OF CARDIO/PERICARDIAL SILHOUETTE AGAIN SEEN. VASCULAR REDISTRIBUTION IS NOTED; INCREASED LEFT RETROCARDIAC ATELECTASIS AND INCREASED SIZE OF LEFT-SIDED PLEURAL EFFUSION.
2. FINDINGS CONSISTENT WITH PERSISTENT PULMONARY EDEMA WITH WORSENING LEFT RETROCARDIAC ATELECTASIS AND LEFT PLEURAL EFFUSION.

Рис. 2: Пример пары снимка и отчёта (раздел Impression) из CheXpert Plus.

Пусть I_i обозначает изображение, а T_i – соответствующий ему текст отчёта. Для каждого объекта сначала строится векторное представление текста

$$h_i = E_{\text{CXR-BERT}}(T_i) \in \mathbb{R}^{d_{\text{in}}},$$

где $E_{\text{CXR-BERT}}$ – текстовый кодировщик CXR-BERT-specialized. Далее это представление подается на вход обучаемого проектора

$$\tilde{y}_i = P_\theta(h_i) \in \mathbb{R}^{d_{\text{out}}},$$

где P_θ – многослойный персептрон, отображающий эмбеддинг CXR-BERT-specialized в визуально-текстовое пространство MedSigLIP [36].

Проектор представляет собой полносвязную сеть с двумя скрытыми слоями. Он принимает на вход вектор $h \in \mathbb{R}^{d_{\text{in}}}$ – глобальное представление текста, извлечённое из CLS-токена. Далее применяется последовательность линейных преобразований с размерами слоёв

$$d_{\text{in}} \to 1024 \to 512 \to d_{\text{out}},$$

где d_{out} совпадает с размерностью визуальных признаков MedSigLIP. Между внутренними линейными слоями используется функция активации GELU и регуляризация dropout (случайное зануление части признаков) с вероятностью 0.1.

Далее к визуальным и текстовым представлениям применяется L_2-нормализация:

$$x_i = \frac{v_i}{\|v_i\|_2}, \qquad y_i = \frac{\tilde{y}_i}{\|\tilde{y}_i\|_2},$$

где v_i – векторное представление изображения I_i в пространстве MedSigLIP, а y_i – нормированная проекция текстового эмбеддинга. Тогда попарное сходство между изображением I_i и текстом T_j определяется как скалярное произведение

$$s_{ij} = x_i^\top y_j.$$

Далее вводятся обучаемые скалярные параметры t' и b, причём

$$t = \exp(t').$$

Тогда логит (линейный отклик перед применением сигмоиды) для пары (I_i, T_j) равен

$$\ell_{ij} = t\, x_i^\top y_j + b.$$

Как и в оригинальной статье авторов SigLIP, параметр t' отвечает за масштабирование сходства, а параметр b компенсирует сильный дисбаланс между числом положительных и отрицательных пар в мини-батче (группе примеров, одновременно подаваемых модели).

Для мини-батча размера $|B|$ формируется матрица меток

$$z_{ij} = \begin{cases} 1, & i = j, \\ -1, & i \neq j, \end{cases}$$

то есть диагональные элементы соответствуют истинным парам «изображение-текст», а все внедиагональные элементы – отрицательным парам. Тогда попарная сигмоидная функция потерь записывается как

$$\mathcal{L}_{\text{SigLIP}} = -\frac{1}{|B|} \sum_{i=1}^{|B|} \sum_{j=1}^{|B|} \log \sigma\big(z_{ij} \left(t\, x_i^\top y_j + b\right)\big),$$

где $\sigma(\cdot)$ – функция сигмоиды.

С практической точки зрения обучение устроено следующим образом. Для каждого мини-батча берутся визуальные представления изображений в пространстве MedSigLIP

и текстовые представления отчётов, полученные CXR-BERT-specialized. Далее обучаемый проектор P_θ преобразует текстовые эмбеддинги в то же пространство, после чего вычисляется попарная сигмоидная функция потерь по всем парам внутри батча. Минимизация этой функции приводит к тому, что проекция текста, соответствующего данному изображению, приближается к векторному представлению снимка, тогда как проекции остальных отчётов становятся дальше. В результате после обучения проектор реализует отображение

$$P_\theta : \mathbb{R}^{d_{\text{in}}} \to \mathbb{R}^{d_{\text{out}}},$$

согласующее текстовые представления, полученные с помощью кодировщика CXR-BERT-specialized, с визуально-текстовым пространством MedSigLIP.

После завершения обучения для пары «снимок-отчёт» можно вычислять согласованность между изображением и текстом как сходство

$$\text{score}_{\text{img-text}}(I, T) = x^\top y,$$

где x – нормированное векторное представление снимка, а y – нормированная проекция текстового векторного представления отчёта. Эта величина затем используется как базовая компонента в составе предлагаемого итогового способа оценки качества радиологического заключения.

3.4. Кросс-валидация

Пусть задан набор объектов

$$D = \{(x_i, y_i)\}_{i=1}^{N},$$

где x_i – i-я запись набора данных, включающая изображение, эталонный отчёт, кандидатный отчёт и вычисленные значения базовых оценочных сигналов, а y_i – целевая величина, характеризующая качество кандидатного отчёта. В данной работе в качестве целевой величины используется число клинически значимых ошибок в кандидатном заключении относительно эталона.

Каждая допустимая конфигурация $c \in C$ задается выбором трёх компонент:

1) русскоязычной клинической компоненты;

2) одной текстовой компоненты;

3) одной визуально-текстовой компоненты.

Кроме того, конфигурация неявно включает используемый переводчик, поскольку англоязычные способы оценки вычисляются по английской версии отчётов. Для объекта x_i и конфигурации c формируется вектор признаков

$$\mathbf{f}_i^{(c)} = \left(f_{\text{ru},i}^{(c)}, f_{\text{text},i}^{(c)}, f_{\text{img},i}^{(c)} \right).$$

Поскольку значения различных компонент имеют разные масштабы, перед смешиванием выполняется стандартизация признаков. Для каждого признака $j \in \{\text{ru}, \text{text}, \text{img}\}$ на обучающей части текущего разбиения выборки (фолда) вычисляются выборочное среднее μ_j и стандартное отклонение σ_j, после чего выполняется преобразование

$$z_{j,i}^{(c)} = \frac{f_{j,i}^{(c)} - \mu_j}{\sigma_j}.$$

Если для некоторого признака стандартное отклонение оказывается близким к нулю, то в реализации оно заменяется единицей, чтобы избежать деления на нуль. Вычисление параметров стандартизации по обучающей части соответствующего разбиения исключает утечку информации.

Итоговая оценка качества для объекта x_i в конфигурации c задается как линейная комбинация нормированных признаков:

$$S_i^{(c,\mathbf{w})} = w_{\text{ru}} z_{\text{ru},i}^{(c)} + w_{\text{text}} z_{\text{text},i}^{(c)} + w_{\text{img}} z_{\text{img},i}^{(c)},$$

где вектор весов $\mathbf{w} = \left(w_{\text{ru}}, w_{\text{text}}, w_{\text{img}}\right)$ удовлетворяет ограничениям

$$w_{\text{ru}} > 0, \qquad w_{\text{text}} \geqslant 0, \qquad w_{\text{img}} > 0, \qquad w_{\text{ru}} + w_{\text{text}} + w_{\text{img}} = 1.$$

Поскольку высокая оценка $S_i^{(c,\mathbf{w})}$ должна соответствовать более качественному отчёту, а большее значение y_i соответствует большему числу ошибок, желаемая связь между ними является отрицательной. Поэтому в качестве целевой функции используется величина

$$J(c, \mathbf{w}) = -\tau\left(S^{(c,\mathbf{w})}, y\right),$$

где $\tau(\cdot, \cdot)$ – коэффициент корреляции Кендалла между вектором итоговых оценок и вектором числа ошибок.

Ранговая корреляция Кендалла широко используется в работах по оценке качества радиологических отчётов при сопоставлении автоматических оценочных сигналов с врачебной оценкой. Кроме того, ранговый характер коэффициента делает его менее чувствительным к единичным выбросам и не требует предположения о нормальности распределения или линейности связи. Коэффициент корреляции Кендалла задаётся следующим образом:

$$\tau = \frac{N_{\text{согл}} - N_{\text{несогл}}}{n(n-1)/2},$$

где n – число объектов, $N_{\text{согл}}$ – число согласованных пар объектов, а $N_{\text{несогл}}$ – число несогласованных пар. Знаменатель $n(n-1)/2$ равен общему числу всех попарных сравнений между объектами. Пара объектов i и j считается согласованной, если

$$\left(S_i^{(c,\mathbf{w})} - S_j^{(c,\mathbf{w})}\right)\left(y_i - y_j\right) > 0,$$

и несогласованной, если

$$\left(S_i^{(c,\mathbf{w})} - S_j^{(c,\mathbf{w})}\right)\left(y_i - y_j\right) < 0.$$

Подбор весов осуществляется перебором по сетке на двухмерном симплексе. Пусть шаг сетки равен h. Тогда множество допустимых весов имеет вид

$$\mathcal{W}_h = \left\{ \mathbf{w} \in \mathbb{R}^3 \;\middle|\; \begin{array}{l} w_{\text{ru}}, w_{\text{img}} > 0;\ w_{\text{text}} \geqslant 0; \\ w_{\text{ru}} + w_{\text{text}} + w_{\text{img}} = 1;\ w_{\text{ru}}, w_{\text{text}}, w_{\text{img}} \in h\mathbb{Z} \end{array} \right\}.$$

Для корректной оценки качества не одной фиксированной конфигурации, а всей процедуры её выбора в работе используется вложенная кросс-валидация. Внешний цикл разбивает набор данных на K_{outer} фолдов. На каждом шаге один внешний фолд используется как тестовый, а остальные $K_{\text{outer}} - 1$ фолдов – как внешняя обучающая часть. Именно на этой внешней обучающей части выполняется выбор конфигурации и подбор весов.

Внутри каждого внешнего шага запускается внутренний цикл из K_{inner} фолдов. Для каждой конфигурации $c \in C$ и для каждого внутреннего разбиения последовательно выполняются следующие действия:

1) на внутренней обучающей части вычисляются параметры стандартизации;

2) на этой же части перебором по множеству $\mathcal{W}_h$ выбирается вектор весов

$$\mathbf{w}^* = \arg\max_{\mathbf{w} \in \mathcal{W}_h} J_{\text{train}}(c, \mathbf{w});$$

3) найденные параметры стандартизации и веса переносятся на внутреннюю валидационную часть;

4) на валидационной части вычисляется значение

$$J_{\text{val}}(c, \mathbf{w}^*).$$

После прохождения всех внутренних фолдов для каждой конфигурации вычисляется среднее значение

$$\overline{J}_{\text{inner}}(c) = \frac{1}{K_{\text{inner}}} \sum_{\ell=1}^{K_{\text{inner}}} J_{\text{val}}^{(\ell)}(c)$$

и стандартное отклонение этой величины по внутренним фолдам. В качестве лучшей выбирается конфигурация

$$c^* = \arg\max_{c \in C} \overline{J}_{\text{inner}}(c).$$

После выбора лучшей конфигурации c^* по внешней обучающей части выборки заново пересчитываются параметры стандартизации и снова перебором по сетке находится оптимальный вектор весов

$$\mathbf{w}^*_{\text{outer}} = \arg\max_{\mathbf{w} \in \mathcal{W}_h} J_{\text{outer_train}}(c^*, \mathbf{w}).$$

Затем найденные параметры применяются к внешнему тестовому фолду, и на нем вычисляется итоговое значение

$$J_{\text{outer_test}} = -\tau(S_{\text{outer_test}}, y_{\text{outer_test}}).$$

Описанная процедура повторяется для всех внешних фолдов. В результате получается набор внешних оценок

$$J_1, J_2, \ldots, J_{K_{\text{outer}}},$$

по которым далее вычисляются среднее значение, стандартное отклонение и доверительный интервал.

4. Результаты

4.1. Конфигурация экспериментов

Экспериментальная проверка предложенного способа оценки качества русскоязычных радиологических отчётов проводилась на наборе данных из 100 исследований. В экспериментах использовалась одна фиксированная русскоязычная клиническая компонента, а также 35 текстовых и 10 визуально-текстовых оценок. После сопоставления текстовых и визуально-текстовых компонент по общему суффиксу, соответствующему переводчику и режиму использования терминологии при подготовке английской версии отчёта, было сформировано 70 допустимых конфигураций. На каждом шаге вложенной кросс-валидации способ автоматически выбирал одну из 70 троек вида

$$(\text{ru-компонента},\ \text{text-компонента},\ \text{img-компонента}),$$

после чего для неё подбирал веса линейного смешивания.

Оценка выполнялась по схеме вложенной кросс-валидации с параметрами

$$K_{\text{outer}} = 5, \qquad K_{\text{inner}} = 5.$$

Подбор весов осуществлялся перебором по сетке на симплексе с шагом

$$h = 0.05.$$

4.2. Количественные результаты

Главным результатом эксперимента является оценка качества предложенного подхода на внешних тестовых разбиениях. Среднее значение целевой функции $J_{\text{outer}} = -\tau$ по пяти внешним фолдам составило $\overline{J}_{\text{outer}} = 0.5927$, стандартное отклонение – 0.1491, а 95%-й доверительный интервал – [0.4621; 0.7234].

Поскольку в работе используется величина $J = -\tau(S, y)$, где S – итоговая оценка качества отчёта, а y – число ошибок, полученный результат соответствует средней корреляции Кендалла $\overline{\tau}_{\text{outer}} = -0.5927$. Таким образом, между итоговой оценкой качества и числом ошибок наблюдается устойчивая отрицательная связь: чем выше итоговая оценка, тем, как правило, меньше число ошибок в отчёте. Эта зависимость показана на рис. 3.

Значения J_{outer} по отдельным внешним фолдам составили:

$$0.5064, \quad 0.4265, \quad 0.7503, \quad 0.5296, \quad 0.7508.$$

Разброс по фолдам заметен из-за малого объёма данных, что также иллюстрируется на рис. 4, однако во всех случаях знак корреляции остается правильным, а сама связь между итоговой оценкой и числом ошибок остается отрицательной. В то же время доверительный интервал остается достаточно широким. Это связано с тем, что оценка строится всего по пяти внешним фолдам и по относительно небольшому набору из 100 объектов. Поэтому полученные результаты следует интерпретировать как подтверждение работоспособности

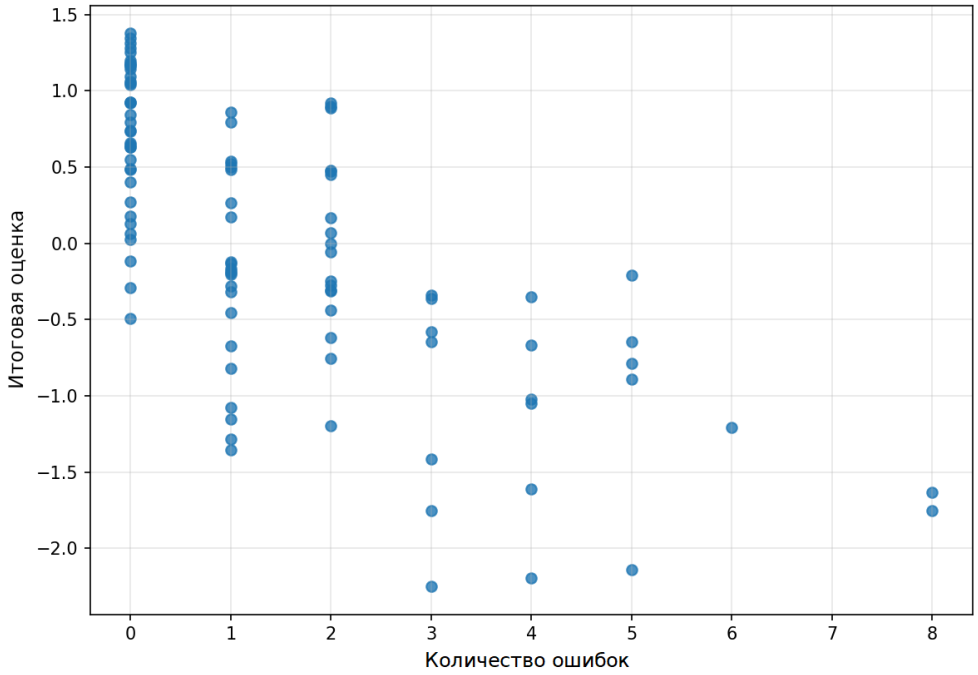


Рис. 3: Связь итоговой оценки качества отчёта с числом ошибок на объединении внешних тестовых фолдов.

предложенного способа оценки в условиях ограниченных данных, а не как окончательную и исчерпывающую оценку его качества на всех возможных русскоязычных радиологических корпусах.

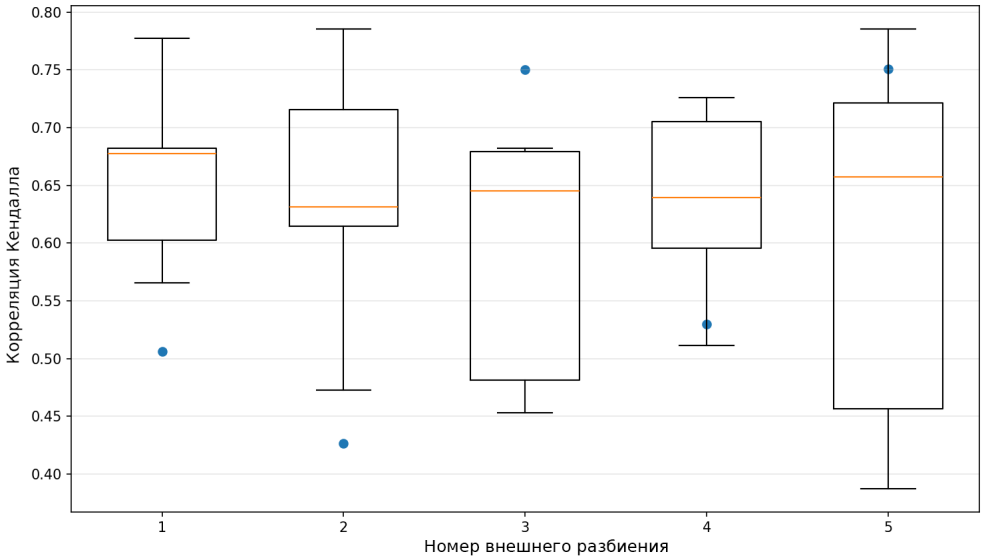


Рис. 4: Сопоставление распределения значений целевой функции на внутренних валидационных разбиениях для выбранной конфигурации с её значением на соответствующем внешнем тестовом разбиении: ящичные диаграммы показывают разброс значений на внутренних разбиениях, отдельные точки – значения на внешнем тестовом разбиении.

Не менее важным результатом является распределение весов между тремя компонентами итоговой оценки качества. Средние значения весов по пяти внешним фолдам составили:

$$\overline{w}_{\text{ru}} = 0.11, \qquad \overline{w}_{\text{text}} = 0.59, \qquad \overline{w}_{\text{img}} = 0.30.$$

Следовательно, наибольший вклад в итоговую оценку качества в среднем вносила текстовая компонента. Визуально-текстовая компонента также вносила существенный вклад, однако в среднем уступала текстовой. Русскоязычная клиническая компонента имела наименьший средний вес, но при этом сохранялась во всех выбранных решениях и давала интерпретируемый результат.

По отдельным фолдам веса изменялись в следующих диапазонах:

$$w_{\text{ru}} \in [0.05;\ 0.15], \qquad w_{\text{text}} \in [0.45;\ 0.70], \qquad w_{\text{img}} \in [0.15;\ 0.50].$$

Полученные результаты подтверждают, что в условиях дефицита русскоязычных размеченных данных более целесообразно оценивать не один заранее зафиксированный способ, а всю адаптивную процедуру выбора конфигурации и весов. Внешняя вложенная кросс-валидация показывает, что такой подход позволяет устойчиво выявлять отрицательную связь между итоговой оценкой качества и числом ошибок, причём делает это без обучения новой крупной специализированной модели.

По результатам экспериментов можно сделать следующие выводы: предложенный способ оценки качества русскоязычных радиологических отчётов органов грудной клетки:

1) корректно работает в условиях малого объёма данных;
2) устойчиво сочетает три источника информации – русскоязычный клинический, текстовый и визуально-текстовый;
3) чаще всего опирается на текстовую семантическую близость как на основной сигнал;
4) использует визуально-текстовую согласованность как значимую дополнительную компоненту;
5) требует рассматривать результат именно как процедуру выбора, а не как одну универсальную фиксированную формулу.

4.3. Дальнейшее развитие

В условиях дефицита размеченных данных обучение русскоязычной клинической текстовой модели с нуля невозможно. Поэтому была предложена методика оценки, состоящая из комбинации методов трёх семейств: русскоязычная большая языковая модель для интерпретации ошибок, отобранные на этапе предварительного сравнения методы сопоставления текста-кандидата с эталоном и с рентгенограммой, включающие предварительный машинный перевод на английский язык с последующим применением готовых англоязычных методов. Оценка качества работы самой методики производилась с помощью вложенной кросс-валидации, что позволило получить несмещённую оценку обобщающей способности подхода в целом.

Среди потенциальных путей совершенствования предложенной методики следует отметить возможную врачебную валидацию автоматического перевода набора данных. Другим

перспективным направлением для будущих работ может стать доработка алгоритмов с учётом их соответствия российским стандартам написания рентгенологических отчётов. Это позволило бы лучше адаптировать подход под специфику отечественного здравоохранения и повысить его практическую значимость.

5. Заключение

В рамках выпускной квалификационной работы:

- Сформирован экспериментальный набор данных для оценки качества русскоязычных радиологических отчётов.
- Разработаны метод оценки русскоязычных радиологических отчётов с использованием текстовых и мультимодальных нейросетевых моделей и методика адаптивного отбора и настройки его компонент.
- Показана согласованность предложенного метода с врачебными оценками.

Алгоритмы, реализующие разработанные метод и методику его настройки, написаны на языке Python 3.

Список литературы

1. Retrieval-Based Chest X-Ray Report Generation Using a Pre-trained Contrastive Language-Image Model / M. Endo [и др.] // Proceedings of Machine Learning for Health. Т. 158. — PMLR, 12.2021. — С. 209—219. — (Proceedings of Machine Learning Research).
2. Evaluating progress in automatic chest X-ray radiology report generation / F. Yu [и др.] // Patterns. — 2023. — Т. 4, № 9. — С. 100802.
3. Advancements in Radiology Report Generation: A Comprehensive Analysis / D. Mamdouh [и др.] // Bioengineering. — 2025. — Т. 12, № 7. — С. 693.
4. Combining Automatic Labelers and Expert Annotations for Accurate Radiology Report Labeling Using BERT / A. Smit [и др.] // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). — Online : Association for Computational Linguistics, 11.2020. — С. 1500—1519.
5. RadGraph: Extracting Clinical Entities and Relations from Radiology Reports / S. Jain [и др.]. — 2021.
6. GREEN: Generative Radiology Report Evaluation and Error Notation / S. Ostmeier [и др.] // Findings of the Association for Computational Linguistics: EMNLP 2024. — Association for Computational Linguistics, 2024. — С. 374—390. — DOI: 10.18653/v1/2024.findings-emnlp.21.
7. FineRadScore: A Radiology Report Line-by-Line Evaluation Technique Generating Corrections with Severity Scores / A. Huang [и др.] // Proceedings of the 9th Machine Learning for Healthcare Conference. Т. 252. — PMLR, 08.2024. — (Proceedings of Machine Learning Research).
8. BLEU: a Method for Automatic Evaluation of Machine Translation / K. Papineni [и др.] // Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. — Philadelphia, Pennsylvania, USA : Association for Computational Linguistics, 2002. — С. 311—318.
9. *Banerjee S.*, *Lavie A.* METEOR: An Automatic Metric for MT Evaluation with Improved Correlation with Human Judgments // Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization. — Ann Arbor, Michigan : Association for Computational Linguistics, 2005. — С. 65—72.

10. *Lin C.-Y.* ROUGE: A Package for Automatic Evaluation of Summaries // Text Summarization Branches Out. — Barcelona, Spain : Association for Computational Linguistics, 2004. — С. 74—81.

11. *Vedantam R.*, *Zitnick C. L.*, *Parikh D.* CIDEr: Consensus-Based Image Description Evaluation // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — IEEE Computer Society, 2015. — С. 4566—4575.

12. SPICE: Semantic Propositional Image Caption Evaluation / P. Anderson [и др.] // Computer Vision – ECCV 2016. Т. 9909. — Springer, 2016. — С. 382—398. — (Lecture Notes in Computer Science).

13. BERTScore: Evaluating Text Generation with BERT / T. Zhang [и др.] // Proceedings of the 8th International Conference on Learning Representations (ICLR). — OpenReview.net, 2020.

14. RaTEScore: A Metric for Radiology Report Generation / W. Zhao [и др.] // Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. — Miami, Florida, USA : Association for Computational Linguistics, 11.2024. — С. 15004—15019. — DOI: 10.18653/v1/2024.emnlp-main.836.

15. ReXrank: A Public Leaderboard for AI-Powered Radiology Report Generation / X. Zhang [и др.] // Proceedings of The First AAAI Bridge Program on AI for Medicine and Healthcare. Т. 281. — PMLR, 2025. — С. 90—99. — (Proceedings of Machine Learning Research).

16. *Remy F.*, *Demuynck K.*, *Demeester T.* BioLORD-2023: semantic textual representations fusing large language models and clinical knowledge graph insights // Journal of the American Medical Informatics Association. — 2024. — Т. 31, № 9. — С. 1844—1855.

17. *Gupta A.* Analyzing multimodal machine learning model performance and evaluation metrics for medical report generation : дис. . . . канд. / Gupta Ankit. — Carnegie Mellon University Pittsburgh, PA, 2024.

18. CREPE: Rapid Chest X-ray Report Evaluation by Predicting Multi-category Error Counts / G. Cho [и др.] // Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. — Association for Computational Linguistics, 2025. — С. 21738—21755. — DOI: 10.18653/v1/2025.emnlp-main.1102.

19. GEMA-Score: Granular Explainable Multi-Agent Score for Radiology Report Evaluation / Z. Zhang [и др.]. — 2025.

20. Radiology Report Generation Models Evaluation Dataset For Chest X-rays (RadEvalX) / A. R. Calamida [и др.] // PhysioNet. — 2024. — Июнь. — DOI: 10.13026/tp88-q278. — Version 1.0.0.

21. Radiology-Aware Model-Based Evaluation Metric for Report Generation / A. R. Calamida [и др.]. — 2023.

22. Preparing a collection of radiology examinations for distribution and retrieval / D. Demner-Fushman [и др.] // Journal of the American Medical Informatics Association. — 2016. — Т. 23, № 2. — С. 304—310. — DOI: 10.1093/jamia/ocv080.

23. Fleischner Society: Glossary of Terms for Thoracic Imaging / A. A. Bankier [и др.] // Radiology. — 2024. — Т. 310, № 2. — e232558. — DOI: 10.1148/radiol.232558.

24. Терминология описания органов грудной клетки – рентгенография и компьютерная томография: методические рекомендации. Т. 121. — М. : ГБУЗ “НПКЦ ДиТ ДЗМ”, 2022. — (Лучшие практики лучевой и инструментальной диагностики). — сост. А. Е. Николаев, М. М. Сучилова, О. А. Коркунова [и др.]. – 84 с.

25. *OpenAI*. GPT-5.2 Large Language Model. — 2026. — https://openai.com.

26. Improving the Factual Correctness of Radiology Report Generation with Semantic Rewards / J.-B. Delbrouck [и др.] // Findings of the Association for Computational Linguistics: EMNLP 2022. — Association for Computational Linguistics, 2022. — С. 4348—4360.

27. Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing / B. Boecking [и др.] // European Conference on Computer Vision (ECCV). — 2022. — С. 1—21. — DOI: 10.1007/978-3-031-20059-5_1.

28. Learning to Exploit Temporal Structure for Biomedical Vision-Language Processing / S. Bannur [и др.] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2023. — DOI: 10.1109/CVPR52729.2023.01442.

29. TranslateGemma Technical Report / M. Finkelstein [и др.] // arXiv preprint arXiv:2601.09012. — 2026.

30. HY-MT1.5 Technical Report / M. Zheng [и др.] // arXiv preprint arXiv:2512.24092. — 2025.

31. *Qwen Team*. Qwen3.5-Omni Technical Report // arXiv preprint arXiv:2604.15804. — 2026.

32. MIMIC-CXR Database / A. Johnson [и др.] // PhysioNet. — 2019. — DOI: 10.13026/C2JT1Q. — Version 2.0.0.

33. MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports / A. E. W. Johnson [и др.] // Scientific Data. — 2019. — Т. 6. — С. 317. — DOI: 10.1038/s41597-019-0322-0.

34. Sigmoid Loss for Language Image Pre-Training / X. Zhai [и др.]. — 2023.

35. CheXpert Plus: Augmenting a Large Chest X-ray Dataset with Text Radiology Reports, Patient Demographics and Additional Image Formats / P. Chambon [и др.]. — 2024.

36. Medgemma technical report / A. Sellergren [и др.] // arXiv preprint arXiv:2507.05201. — 2025.